HOOFDSTUK 14

Het datawarehouse

Leerdoelen:

- de gegevensbehoeften van transactieverwerkende systemen kunnen vergelijken met die van beslissingondersteunende systemen;
- kunnen beschrijven wat wordt bedoeld met een datawarehouse en de belangrijkste kenmerken van een datawarehouse kunnen noemen;
- het enterprise-datawarehouse kunnen vergelijken met de datamart;
- een datawarehouse kunnen ontwerpen;
- een datawarehouse kunnen bouwen, inclusief de stappen van het extraheren, schonen, transformeren en laden van gegevens;
- kunnen beschrijven hoe een datawarehouse wordt gebruikt bij interactieve analytische verwerking en data-mining;
- de soorten expertise kunnen noemen die nodig zijn om een datawarehouse te beheren;
- de uitdagingen van datawarehousing kunnen noemen.

Smith & Nephew

Smith & Nephew is een bedrijf dat toonaangevend is in de vervaardiging en marketing van medische hulpmiddelen. Het bedrijf heeft zijn hoofdkantoor in Londen in Groot-Brittannië, heeft meer dan zevenduizend werknemers en is actief in vierendertig landen. Smith & Nephew richt zich op drie gebieden van medische hulpmiddelentechnologie, die in aparte bedrijfsonderdelen zijn ondergebracht. Op het gebied van de orthopedie is Smith & Nephew een belangrijke fabrikant van kunstgewrichten voor knie, heup en schouder, alsmede van producten die kunnen helpen bij het herstel van botbreuken (zie foto). Op het gebied van de endoscopie is het bedrijf wereldleider in artroscopie-instrumenten voor minimaal-invasieve operaties aan de knie of andere gewrichten. Tot slot is het bedrijf wereldleider in producten en technieken voor de geavanceerde behandeling van wonden. De aanzet tot dit alles werd gegeven in 1856, toen Thomas J. Smith in het Engelse Hull een apotheek begon. En ja, later is inderdaad ook zijn neef in het bedrijf komen werken.

Smith & Nephew ondersteunt zijn handel in orthopedische producten met een geavanceerd datawarehouse. Dit datawarehouse bevat gegevens over de dagelijkse verkoop- en voorraadgegevens van zijn operationele SAP-systeem plus mondiale gegevens en gegevens van externe bronnen over financiële zaken en de markt. Het datawarehouse biedt een beslissingondersteunende omgeving voor verkoopleiders die verkooprayons moeten beheren en hergroeperen, marketingspecialisten die het

potentieel van markten moeten analyseren, productmanagers en logistieke managers. Het datawarehouse wordt ook gebruikt om een informatie- en beheersingssysteem ten behoeve van de besluitvorming te ondersteunen voor de rapportage van de bedrijfsresultaten aan de leiding van de orthopedische divisie.

Het datawarehouse, dat is geïmplementeerd in 1999, is gebouwd op het relationele Oracle-databasemanagementsysteem en draait op UNIX-hardware van Hewlett-Packard. Queries worden gegenereerd via queryproducten van Oracle, alsmede in SQL. De architectuur van het datawarehouse van Smith & Nephew is gebaseerd op het klassieke sterschema, met diverse grote onderwerpgebieden. Deze gebieden en hun feitentabellen betreffen de omzet in de Verenigde Staten, de wereldwijde verkopen, de begroting en de voorraden. De dimensietabellen, bijvoorbeeld voor de wereldwijde verkopen, bevatten gegevens voor de klant, het tijdstip en het product. Door deze opzet is het mogelijk gegevens over eerdere verkopen op te vragen per klant, verkooprayon, tijdsperiode, product, enzovoort.

Met toestemming van Smith & Nephew



Foto met toestemming van Smith & Nephew

Wanneer we aan informatiesystemen denken, denken we doorgaans aan zogenoemde operationele of **transactieverwerkende systemen** (*transaction processing systems*, TPS). Dit zijn de dagelijkse toepassingensystemen die de activiteiten van banken en verzekeringsmaatschappijen ondersteunen, de onderdelenvoorraden voor assemblagelijnen in een fabriek beheren, de reserveringen van een luchtvaartmaatschappij of hotel bijhouden, de online verkopen van een bedrijf ondersteunen, enzovoort. Het zijn het soort toepassingensystemen dat de meeste mensen gemakkelijk associëren met informatiesystemen en het zijn eigenlijk ook het soort toepassingensyste-

men dat we in dit boek als voorbeeld hebben gebruikt. De databases die deze toepassingensystemen ondersteunen, moeten een aantal dingen met elkaar gemeen hebben, die we doorgaans als vanzelfsprekend aannemen. Zo moeten ze bijvoorbeeld zeer actuele gegevens bevatten, directe toegang bieden, zeer snel kunnen reageren en zo zijn opgezet, dat een groot aantal gebruikers gelijktijdig het systeem kan gebruiken.

Het bedrijfsleven heeft echter ook nog behoeften van geheel andere aard. Deze behoeften hebben doorgaans te maken met de besluitvorming van de leiding en hiervoor moeten gewoonlijk gegevens worden geanalyseerd die in de loop van een bepaalde tijd zijn verzameld. Vaak zijn er niet eens zeer recente gegevens voor nodig! We hebben al de behoeften gezien van Smith & Nephew om zijn marketingactiviteiten te beheren. Een ander voorbeeld is dat van detailhandelzaken waar de bedrijfsleiding moet beslissen hoeveel stuks van elk artikel ze dit jaar op voorraad willen hebben voor de maanden oktober tot en met december; de bedrijfsleiding zal daarvoor de omzet voor die artikelen in de laatste drie maanden van de afgelopen vijf jaar willen bestuderen. Als de leiding van een luchtvaartmaatschappij overweegt meer vluchten tussen twee steden te gaan uitvoeren (of om bestaande vluchten te laten vervallen), zal de leiding allerlei verzamelde gegevens willen analyseren over het aantal passagiers tussen de twee steden op de bestaande vluchten. Als een bedrijf overweegt zijn activiteiten uit te breiden naar een nieuwe geografische regio, zal de bedrijfsleiding de demografische gegevens van de bevolking in die regio willen bestuderen, almede de hoeveelheid concurrentie die het van andere bedrijven kan verwachten en waarschijnlijk zal de leiding daarvoor gegevens gebruiken die het bedrijf nog niet heeft, maar van derden zal moeten kopen.

Er is een andere klasse van toepassingensystemen die tegemoet komt aan dergelijke behoeften voor de besluitvorming van de leiding, en wel de zogenoemde **beslissingondersteunende systemen** (*decision support systems*, DSS). Deze systemen zijn specifiek bedoeld om managers bij zulke taken te helpen. Ze zijn in dit boek voor ons van belang vanwege de vraag welk type database nodig is als basis van een DSS. In het verleden zijn bestanden ontwikkeld ter ondersteuning van afzonderlijke toepassingen die we nu als DSS-toepassingen zouden bestempelen. De hierboven beschreven trendanalyse van de vijfjarenverkopen voor detailhandelzaken is bijvoorbeeld al lange tijd een tamelijk gangbare toepassing en is altijd ondersteund door bestanden die speciaal voor die toepassing waren gemaakt. De DSS-activiteit is echter explosief toegenomen, net als die van de overige informatiesystemen. Het is om diverse redenen verspillend, duur en inefficiënt om voor elke DSS-toepassing aparte bestanden te hebben:

- Vaak hebben verschillende DSS-toepassingen dezelfde gegevens nodig, zodat voor elke toepassing duplicaatbestanden worden gemaakt. Zoals bij alle redundante bestanden, verspillen ze opslagruimte en kost het bijwerken van de bestanden onnodig veel tijd. Bovendien kunnen er problemen met de gegevensintegriteit ontstaan, al zullen we verderop zien dat gege-

vensredundantie bij grotendeels historische gegevens niet zo'n probleem is als bij transactiegegevens.

- Wanneer bepaalde bestanden slechts bepaalde DSS-toepassingen ondersteunen, zijn ze vaak inflexibel en ondersteunen ze vaak geen nauw verwante toepassingen die net iets andere gegevens nodig hebben.
- Afzonderlijke bestanden die zijn verbonden met specifieke DSS-toepassingen, stimuleren andere mensen en groepen in het bedrijf niet om met de verzamelde gegevens van het bedrijf concurrentievoordeel te behalen.
- Zelfs als mensen in het bedrijf weten dat er bestaande gegevens voor een DSS-toepassing zijn waarmee ze voordeel voor het bedrijf zouden kunnen behalen, hebben ze doorgaans geen toegang tot de gegevens omdat deze 'eigendom' zijn van de toepassing waarvoor ze zijn verzameld.

Toen we het eerder in het boek hadden over de voordelen van het delen van gegevens, hebben we de nadruk gelegd op gegevens in transactiesystemen. De bovengenoemde factoren voor gegevens voor beslissingondersteunende systemen, die voor het grootste deel parallellen zijn van die voor gedeelde transactiesystemen, leiden onvermijdelijk tot het concept van brede, gedeelde databases voor de ondersteuning van de besluitvorming. Deze DSS-databases worden **datawarehouses** genoemd. In dit hoofdstuk bespreken we de aard, het ontwerp en de implementatie van datawarehouses. Verderop in dit hoofdstuk gaan we ook kort in op enkele belangrijke toepassingswijzen van datawarehouses.

14.1 Het principe van het datawarehouse

Informeel gezegd is een datawarehouse een brede, gedeelde database ten behoeve van de besluitvorming van de bedrijfsleiding die gegevens bevat die in de loop van de tijd zijn verzameld. Stel u voor dat u aan het einde van elke week of maand alle verkoopgegevens van het bedrijf voor die periode verzamelt en deze toevoegt aan alle verzamelde verkoopgegevens die al in het datawarehouse staan. Wanneer u dit consequent volhoudt, hebt u na enige tijd een verzameling verkoopgegevens die een paar jaar bestrijkt, die u kunt doorzoeken, waaruit u gegevens kunt opvragen en waarop u allerlei soorten berekeningen kunt uitvoeren.

Formeler en preciezer gezegd, is een datawarehouse volgens de klassieke definitie 'een **onderwerpgeoriënteerde, geïntegreerde, niet-vluchtige** en **tijdsafhankelijke** verzameling van gegevens ter ondersteuning van de besluitvorming van de leiding'.[1] De gegevens in het datawarehouse moeten daarnaast van zeer hoge kwaliteit zijn, ze kunnen geaggregeerd zijn, ze zijn vaak gedenormaliseerd en ze hoeven niet helemaal actueel te zijn (zie figuur 14.1). Laten we elk van deze kenmerken van een datawarehouse eens apart bekijken.

1 W.H. Inmon, *Building the Data Warehouse*, 2e editie (Hoboken, NJ: John Wiley & Sons, 1996).

- De gegevens zijn onderwerpgeoriënteerd.
- De gegevens zijn geïntegreerd.
- De gegevens zijn niet-vluchtig.
- De gegevens zijn tijdsafhankelijk.
- De gegevens moeten van hoge kwaliteit zijn.
- De gegevens kunnen geaggregeerd zijn.
- De gegevens zijn vaak gedenormaliseerd.
- De gegevens zijn niet noodzakelijk helemaal actueel.

Figuur 14.1: Kenmerken van gegevens in een datawarehouse

14.1.1 De gegevens zijn onderwerpgeoriënteerd

De gegevens in transactiedatabases zijn vaak geordend volgens de TPS-toepassingen van het bedrijf. Bij een bank kunnen dit de toepassingen zijn die het betalingsverkeer afhandelen, bij een productiebedrijf kunnen het de toepassingen zijn die met de toeleveranciers communiceren om te zorgen dat de assemblagelijn altijd over voldoende grondstoffen en onderdelen beschikt en bij een luchtvaartmaatschappij kunnen het de toepassingen zijn die het reserveringsproces ondersteunen. Datawarehouses worden opgezet rond onderwerpen. Dit zijn eigenlijk de belangrijkste entiteiten die interessant zijn in de bedrijfsomgeving. Onderwerpen kunnen dus verkooptransacties, klanten, bestellingen, claims, rekeningen, werknemers en andere entiteiten zijn die van belang zijn voor de bedrijfsvoering van een bepaald bedrijf.

14.1.2 De gegevens zijn geïntegreerd

De gegevens over elk van de onderwerpen in het datawarehouse zijn gewoonlijk afkomstig van verschillende transactiedatabases van het bedrijf, die elk een of meer toepassingen ondersteunen die iets te maken hebben met het onderwerp in kwestie. Een deel van de gegevens, zoals aanvullende demografische gegevens over de klanten van het bedrijf, zijn mogelijk van derden gekocht. Alle gegevens over een onderwerp moeten zo worden geordend of geïntegreerd, dat ze een verenigd totaalbeeld te zien geven van alle belangrijke details over het onderwerp in de loop van de tijd. De gegevens moeten bovendien niet alleen worden geïntegreerd, maar moeten mogelijk ook worden 'getransformeerd'. De databasetabellen van een toepassing kunnen bijvoorbeeld de afmetingen van de voltooide producten van het bedrijf aangeven in centimeters, terwijl een andere tabel ze in inches aangeeft. De landen in de wereld kunnen in de ene tabel worden geïdentificeerd aan de hand van hun naam, terwijl een andere tabel een numerieke code gebruikt. De ene tabel kan klantnummers opslaan als integers, terwijl een andere ze opslaat als een tekenreeks. In al deze gevallen en in veel andere gevallen moeten de gegevens uit deze uiteenlopende toepassingsdatabases worden getransformeerd naar dezelfde maateenheden, codes, gegevenstypen, enzovoort wanneer ze in het datawarehouse worden geïntegreerd.

14.1.3 De gegevens zijn niet-vluchtig

Transactiegegevens worden doorgaans regelmatig of zelfs vaak bijgewerkt. Het saldo van bankrekeningen, de voorraden van ruwe grondstoffen en de reserveringsgegevens van een luchtvaartmaatschappij worden allemaal bijgewerkt wanneer het saldo van een rekening, de voorraad of het aantal overgebleven stoelen tijdens de normale bedrijfsuitoefening verandert. We noemen deze gegevens vluchtig omdat ze voorturend veranderen. De gegevens in het datawarehouse zijn niet-vluchtig. Wanneer de gegevens eenmaal aan het datawarehouse zijn toegevoegd, veranderen ze niet meer. De omzetgegevens voor oktober 2000 zijn wat ze zijn. De verkoopgegevens zijn eind oktober 2000 bij elkaar opgeteld en aan het datawarehouse toegevoegd, en dat is het dan. De gegevens zullen nooit meer veranderen. Wanneer ze wel zouden worden gewijzigd, zou het zijn alsof u de geschiedenis herschrijft. Het enige opzicht waarin de gegevens in het datawarehouse worden bijgewerkt, is dat gegevens voor de recentste periode, de periode die net is afgelopen, aan de bestaande gegevens worden toegevoegd.

14.1.4 De gegevens zijn tijdsafhankelijk

De meeste transactiegegevens zijn eenvoudigweg 'actueel'. Een saldo van een bankrekening, de voorradige hoeveelheid ruwe grondstoffen, het aantal overgebleven stoelen op een vlucht zijn allemaal actuele cijfers. Als iemand geld van zijn bankrekening wil opnemen, kan het de bank niet schelen wat het rekeningsaldo tien dagen eerder of tien uur eerder was. De bank wil alleen weten wat het *huidige* saldo is. Aan het banksaldo hoeft geen datum of tijd te worden gekoppeld; de gegevens hebben altijd betrekking op het *nu*. (*Sommige* transactiegegevens moeten overigens wel een tijdaanduiding hebben. Een ziektekostenverzekeraar kan claims van het afgelopen half jaar paraat houden, en zulke gegevens hebben duidelijk wel een datumaanduiding nodig.) De gegevens in een datawarehouse hebben daarentegen door hun historische karakter altijd een tijdaanduiding. Als we de verkoopgegevens wekelijks of maandelijks opslaan en we zulke gegevens over een periode van tien jaar hebben verzameld, moet elk week- of maandomzetcijfer vergezeld gaan van een tijdaanduiding die aangeeft op welke week of maand (en jaar!) het cijfer betrekking heeft.

14.1.5 De gegevens moeten van hoge kwaliteit zijn

Bij transactiegegevens zijn niet alle soorten fouten even erg. In het voorbeeld van een bankrekening moet het saldo van een rekening natuurlijk kloppen, maar als het adres van de rekeninghouder een spelfout bevat, zal dat waarschijnlijk weinig verschil maken. Zo'n fout beïnvloedt het rekeningsaldo niet en de postbode zal de rekeningoverzichten waarschijnlijk gewoon op het juiste adres bezorgen. Maar wat als het adres van de rekeninghouder in andere transactiebestanden wel goed is gespeld? Neem eens een segment van een datawarehouse waarin het onderwerp de klant is. Het is dan cruciaal om een kloppende set klanten op te stellen willen

de gegevens in het datawarehouse van enig nut zijn. Als het adres in een bepaald transactiebestand echter verkeerd is gespeld, en de gegevens in dat bestand worden geïntegreerd met de gegevens uit andere transactiebestanden, ontstaan er problemen in de zin dat moet worden bepaald of de beide adressen bij een en dezelfde klant horen of dat ze twee verschillende klanten vertegenwoordigen. Dit moet worden onderzocht en er moet een beslissing worden genomen of de records uit de verschillende bestanden op één of op twee klanten betrekking hebben. In deze zin moeten de gegevens in het datawarehouse van hogere kwaliteit zijn dan de gegevens in de transactiebestanden.

14.1.6 De gegevens kunnen geaggregeerd zijn

Wanneer de gegevens uit de transactiebestanden worden gekopieerd en geïntegreerd in het datawarehouse, zullen ze vaak om minstens drie redenen worden geaggregeerd. De eerste reden is dat leidinggevenden voor hun besluitvorming vaak samengevatte gegevens nodig hebben. Als een manager moet beslissen hoeveel voorraad hij voor de komende decembermaand voor een winkel moet bestellen, op basis van de verkoopgegevens van de decembermaanden in de afgelopen vijf jaar, zijn de maandomzetcijfers natuurlijk nuttig, maar doen de omzetcijfers voor de afzonderlijke dagen van de maand er waarschijnlijk niet veel toe. De tweede reden voor het werken met **geaggregeerde gegevens** in het datawarehouse is dat de historische gedetailleerde gegevens het datawarehouse in veel gevallen alleen al door de enorme hoeveelheid gegevens onaanvaardbaar groot zouden maken. (Ze zijn al groot genoeg!) De derde reden is dat het steeds bij elke query opnieuw samenvatten van gegevens onaanvaardbaar lang zou duren als de gedetailleerde gegevens in het datawarehouse zouden worden opgenomen. De beslissingondersteunende omgeving is evenwel zo breed, dat er in deze omgeving enkele situaties zijn waarin gedetailleerde gegevens *wel* nodig zijn, en sommige datawarehouses bevatten dan ook tot op zekere hoogte gedetailleerde gegevens.

14.1.7 De gegevens zijn vaak gedenormaliseerd

Een van de fundamentele waarheden over databases die we eerder zijn tegengekomen, was dat gegevensredundantie de prestaties van alleenlezenqueries verbetert, maar meer opslagruimte vraagt, meer tijd voor het bijwerken vraagt en problemen met de gegevensintegriteit kan opleveren wanneer de gegevens moeten worden bijgewerkt. We hebben al geconstateerd dat de gegevens in het geval van een datawarehouse niet-vluchtig zijn. De *bestaande* gegevens in het datawarehouse veranderen nooit. Dit maakt dat het datawarehouse van een heel andere aard is! Als het bedrijf bereid is de aanmerkelijke extra ruimte te accepteren die nodig is voor redundante gegevens, kan het profiteren van de betere queryprestaties die redundantie biedt, zonder dat het bedrijf last heeft van de langere bijwerktijd en de potentiële gegevensintegriteitsproblemen. De bestaande gegevens zijn immers historisch en hoeven nooit te worden bijgewerkt!

14.1.8 De gegevens zijn niet noodzakelijk helemaal actueel

Dit is in feite een gevolg van het periodiek laden van nieuwe gegevens in het datawarehouse en is ook al genoemd in paragraaf 14.1.4. Veronderstel dat u de verkoopgegevens over de zojuist verstreken week elke vrijdag in het datawarehouse invoert. De woensdag erna vraagt een manager gegevens uit het datawarehouse op om een bepaalde beslissing te kunnen nemen. De gegevens in het datawarehouse zijn niet 'actueel' in de zin dat de verkoopgegevens van de afgelopen zaterdag tot en met vandaag, woensdag, niet in het datawarehouse staan. De vraag is of dit erg is. Waarschijnlijk is het dat niet. De manager kan bijvoorbeeld bezig zijn met een trendanalyse van de verkoopcijfers over de afgelopen vijf jaar. Wanneer hij naar gegevens over vijf jaar kijkt, maakt het waarschijnlijk weinig uit of de afgelopen vijf dagen in de analyse worden meegenomen of niet.

Hilton Hotels

Hilton Hotels is een van 's werelds tophotelketens. Sinds de opening van het eerste hotel in 1919 is Hilton uitgegroeid tot een onderneming die wereldwijd aanwezig is met momenteel meer dan tweeduizend hotels. Vanuit het hoofdkantoor in Beverly Hills in Californië beheert de onderneming hotels onder de namen Hilton, Conrad, Doubletree, Embassy Suites, Hampton Inn, Hampton Inns and Suites, Hilton Garden Inn en Homewood Suites by Hilton. De bekendste hotels van Hilton Hotels zijn wel het Beverly Hilton in Beverly Hills in Californië, het Waldorf Astoria in New York City en het Hilton Hawaiian Village op Hawaï.

Hilton Hotels is in de bedrijfstak een van de leiders op het punt van informatietechnologie. Een van de moderne databasetoepassingen van Hilton Hotels is zijn Guest Profile Manager (GPM). Dit is een Customer Relation Management-systeem (CRM-systeem) dat op alle 'contactpunten' met de klant probeert gasten te herkennen en te erkennen. Daarbij valt te denken aan e-mail, contacten aan de balie van een hotel, speciale televisiekanalen op de kamers, het voicemailsysteem Audix en extra aandacht tijdens het verblijf. Wanneer een gast bijvoorbeeld incheckt bij een Hilton-hotel, krijgt de baliemedewerker op een beeldscherm informatie over de gast te zien, zodat hij de gast kan begroeten met: 'Fijn u weer te zien, meneer Smit' of 'Welkom, meneer Jansen. Ik begrijp dat dit uw eerste verblijf in dit hotel (of Hilton Hotels) is.' Zowel de baliemedewerker als het huishoudelijk personeel krijgt informatie over de voorkeuren van een klant en over zijn of haar eerdere klachten, zoals dat hij een kamer wil hebben met voldoende waterdruk en dat hij een rustige kamer wil. Bepaalde geselecteerde klanten, zoals klanten die regelmatig in een Hilton-hotel overnachten, kunnen welkom worden geheten met een fruitmand, een fles mineraalwater of een badjas op hun kamer. Het systeem stelt zelfs persoonlijke voicemailberichten op de telefoonbeantwoorder in de kamer van de gast op om de gast welkom te heten.

Het systeem is in maart 2002 ingewijd en maakt gebruik van het databasemanagementsysteem Informix op een Sun Microsystems-platform. De database bevat zowel actuele reserveringsinformatie als oude gegevens van een gast, zodat het een interessante hybride vorm van een transactieverwerkend systeem en een datawarehouse is. De relatie voor hangende reserveringen bevat ongeveer twee miljoen records, terwijl de 'overnachtingensamenvatting' voor een jaar zo'n zestig miljoen records bevat. De database wordt gedeeld voor reserveringen, CRM en ander doeleinden.

Daarnaast wordt een deel van de gegevens voor marketingdoeleinden gekopieerd naar een offline datamart, waarvoor SQL Server als DBMS en SAS-software worden gebruikt. Een deel van de gegevens is ondergebracht in een klassieke datamart met een 'sterschema' met behulp van software van Epiphany. Niet alleen de hotels en het marketingpersoneel van Hilton hebben toegang tot deze gegevens, maar Hilton biedt via zijn website ook zijn gasten toegang tot hun eigen records, met inbegrip van de gegevens over hun eerdere overnachtingen.

Met toestemming van Hilton Hotels

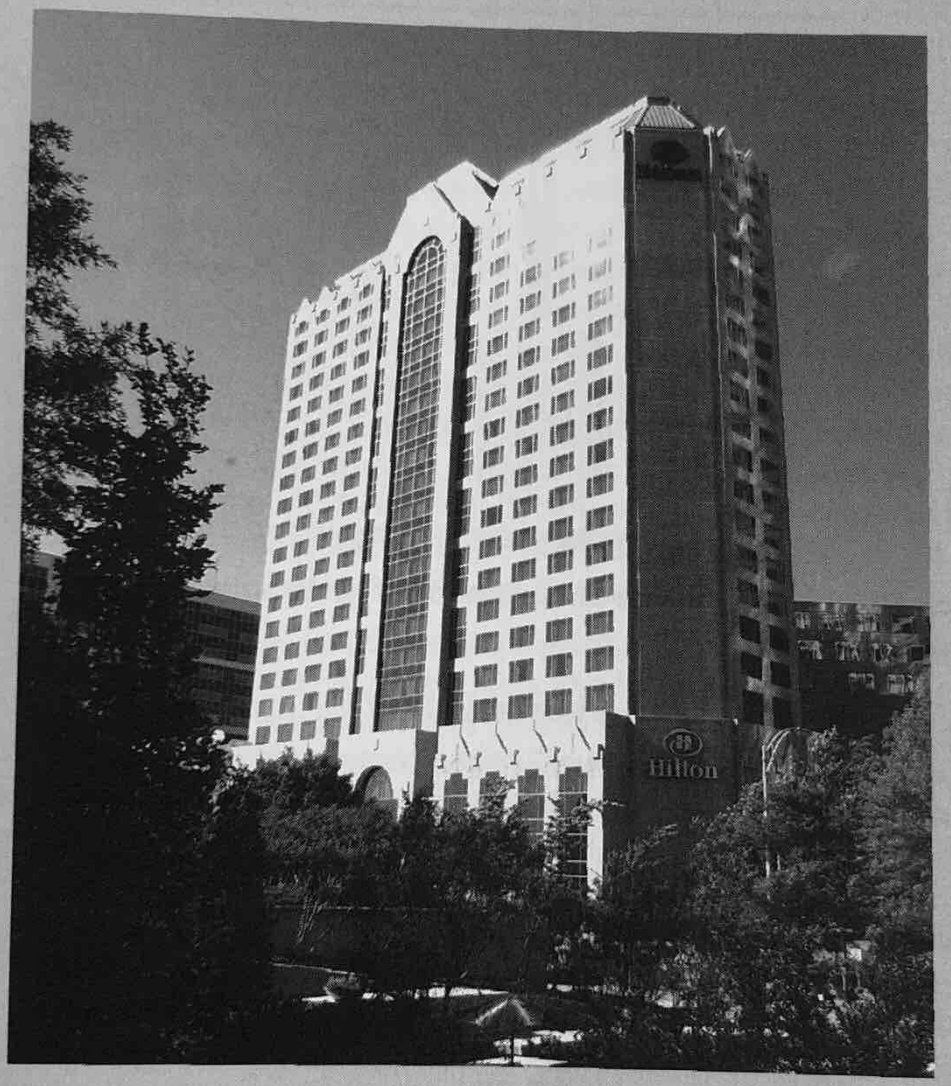
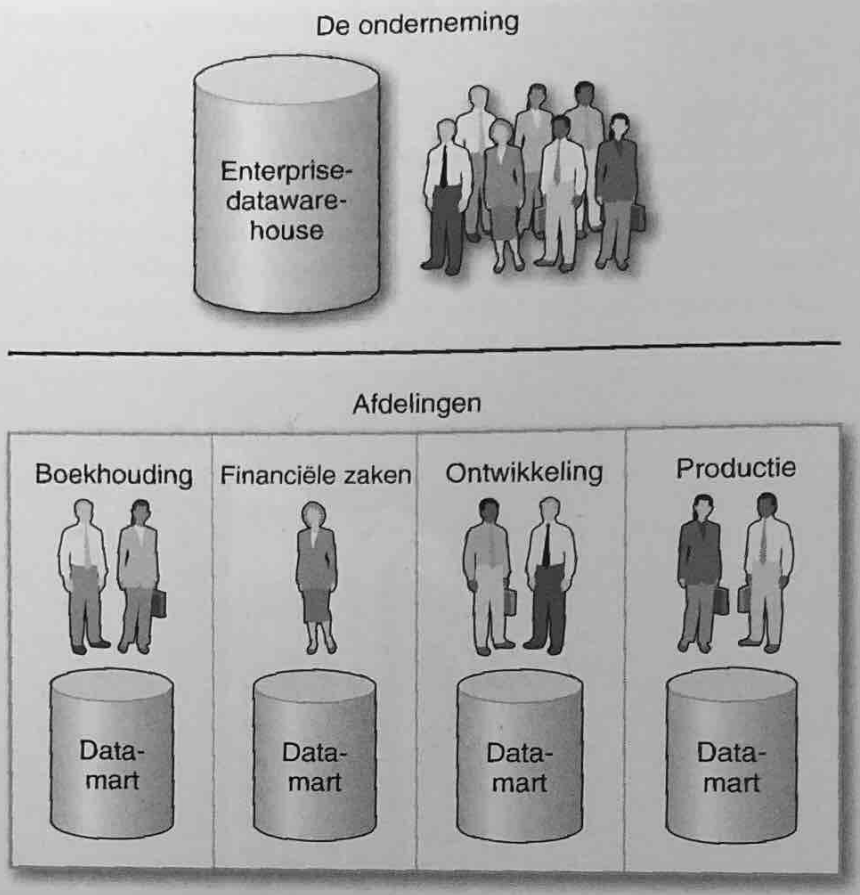


Foto met toestemming van Hilton Hotels

14.2 Typen datawarehouses

Tot nu toe hebben we de term *datawarehouse* in algemene zin gebruikt. Er zijn weliswaar wat variaties en verfijningen, maar in beginsel zijn er slechts twee soorten datawarehouses: het **enterprise-datawarehouse (EDW)** en de **datamart (DM)** (zie figuur 14.2). Er zijn twee categorieën factoren die het onderscheid bepalen: enerzijds de grootte van het datawarehouse en het gedeelte van het bedrijf dat het datawarehouse bedient (wat vaak hand in hand gaat), en anderzijds de manier waarop het datawarehouse is gemaakt en er nieuwe gegevens aan worden toegevoegd (wat ook samenhangt).



Figuur 14.2: Het enterprise-datawarehouse en datamarts

14.2.1 Het enterprise-datawarehouse (EDW)

Het enterprise-datawarehouse is een groot datawarehouse dat de gegevens van een heel bedrijf of van een grote divisie, locatie of activiteit van het bedrijf bevat. Zowel Smith & Nephew als Hilton Hotels heeft dergelijke grote datawarehouses. Afhankelijk van hun aard, worden de gegevens in het EDW uit allerlei transactiedatabases van het bedrijf gehaald, alsmede van externe bronnen. Er moet dus veel aandacht aan de gegevensintegratie worden geschonken. In de terminologie van datawarehouses wordt een volledig EDW gebouwd rond een aantal onderwerpen. De grote hoeveelheid geïntegreerde gegevens in het EDW moet een grote verscheidenheid aan DSS-toepassingen ondersteunen en moet een bedrijfsmiddel zijn waarmee de managers in een bedrijf nieuwe wegen kunnen verkennen om de gegevens van het bedrijf ten bate van het bedrijf aan te wenden. Veel EDW's beperken de mate van denormalisatie, omdat vergaande denormalisatie een enorme hoeveelheid gegevens zou opleveren.

14.2.2 De datamart (DM)

Een datamart is een kleiner datawarehouse dat is bedoeld om een klein deel van een organisatie te ondersteunen, zoals een afdeling of een groep van verwante afdelingen. Zoals we hebben gezien, kopieert Hilton Hotels gegevens van zijn datawarehouse naar een datamart voor marketingqueries.

Een bedrijf heeft vaak meerdere datamarts. Datamarts zijn gebaseerd op een beperkt aantal onderwerpen (mogelijk slechts één) en zijn gebouwd op basis van een beperkt aantal transactiedatabases. Ze concentreren zich op de zaken van een afdeling of een groep van afdelingen en ondersteunen daardoor vaak slechts een beperkt aantal DSS-toepassingen. Door de kleinere omvang die datamarts bij aanvang hebben, is er meer ruimte om gegevens te denormaliseren. Een afdelingsmanager kan ook het gevoel hebben dat hij of zij meer controle over een lokale datamart heeft en een datamart beter kan aanpassen aan de behoeften van de afdeling.

14.2.3 Wat te kiezen: een EDW, DM of beide?

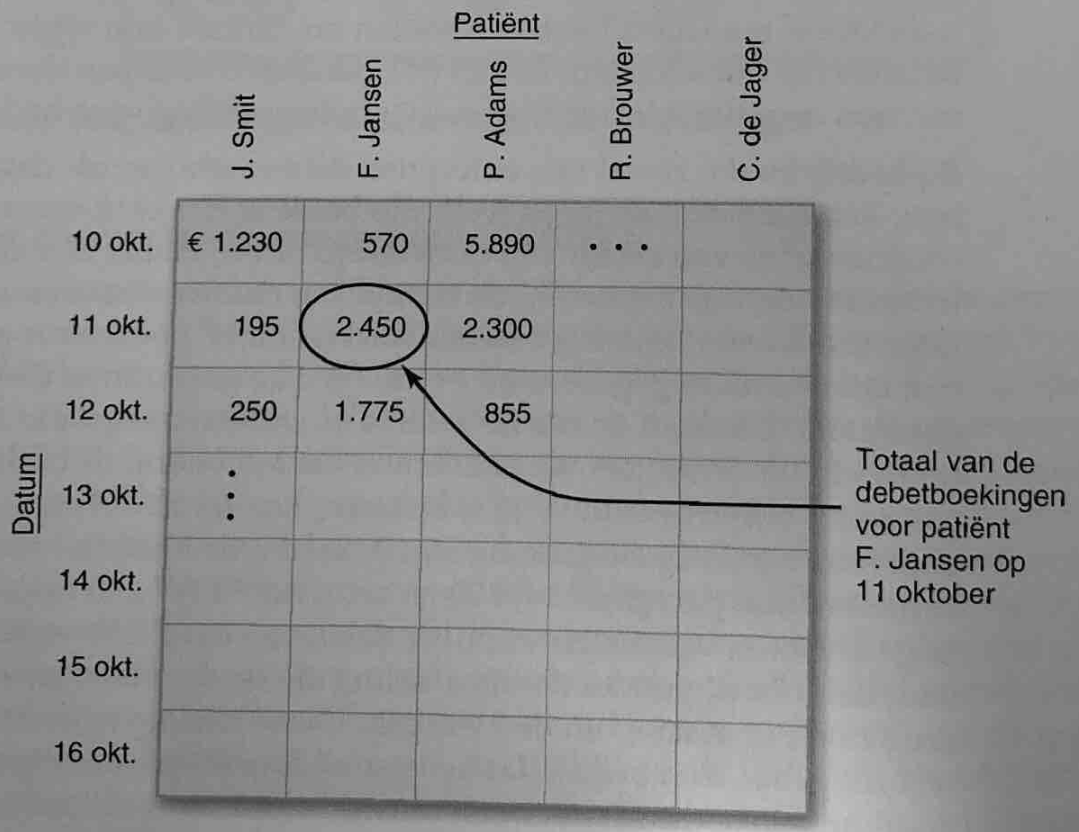
Moet een bedrijf een enterprise-datawarehouse, meerdere datamarts of beide hebben? De keuze kan het resultaat zijn van zorgvuldige planning, maar kan ook gewoon voortvloeien uit de managementstijl of zelfs door toeval worden bepaald. Bepaalde bedrijven hebben inderdaad heel bewust en na zorgvuldige planning besloten om te investeren in de ontwikkeling van een enterprise-datawarehouse. Er zijn ook bedrijven die er bewust voor hebben gekozen een reeks datamarts te ontwikkelen in plaats van een EDW. In andere situaties heeft helemaal geen zorgvuldige planning plaatsgevonden. Er zijn situaties bekend van decentraal geleide bedrijven waarin individuele managers hebben besloten om binnen hun eigen afdeling een datamart te ontwikkelen. Er zijn ook datamarts ontstaan doordat technische mensen in gebruikersafdelingen daar belangstelling voor hadden.

Bij bedrijven die zowel een enterprise-datawarehouse als datamarts hebben, kan men zich afvragen welk van beide er het eerst was en of ze onafhankelijk van elkaar zijn ontwikkeld of van elkaar zijn afgeleid. Dit kan in beide richtingen gaan. In de wereld van datawarehouses wordt met de term *top-downontwikkeling* bedoeld dat het EDW het eerst is gemaakt, dat in een later stadium gegevens uit het EDW zijn geëxtraheerd om een of meer datamarts te maken en dat de datamarts worden aangevuld met gegevens uit het EDW. Wanneer we aannemen dat het bedrijf de beslissing heeft genomen om in een EDW te investeren, kan dit zinvol zijn. Wanneer de gegevens bijvoorbeeld grondig zijn bekeken, de kwaliteit van de gegevens is verbeterd (zie paragraaf 14.4.2) en ze in het EDW zijn opgenomen, blijft de hoge kwaliteit behouden wanneer delen van het EDW worden gedownload naar datamarts, zonder dat de afdeling die de datamart ontwikkelt, zich druk hoeft te maken om de kwaliteit. Ontwikkeling in de andere richting is ook mogelijk. Een bedrijf dat bewust of door de omstandigheden een reeks onafhankelijke datamarts heeft ontwikkeld, kan besluiten om via *bottom-upontwikkeling* een EDW te bouwen op basis van de bestaande datamarts. In dit geval moeten de gegevens eerst verder worden geïntegreerd en getransformeerd dan al is gebeurd voor het maken van de afzonderlijke datamarts.

14.3 Een datawarehouse ontwerpen

14.3.1 Inleiding

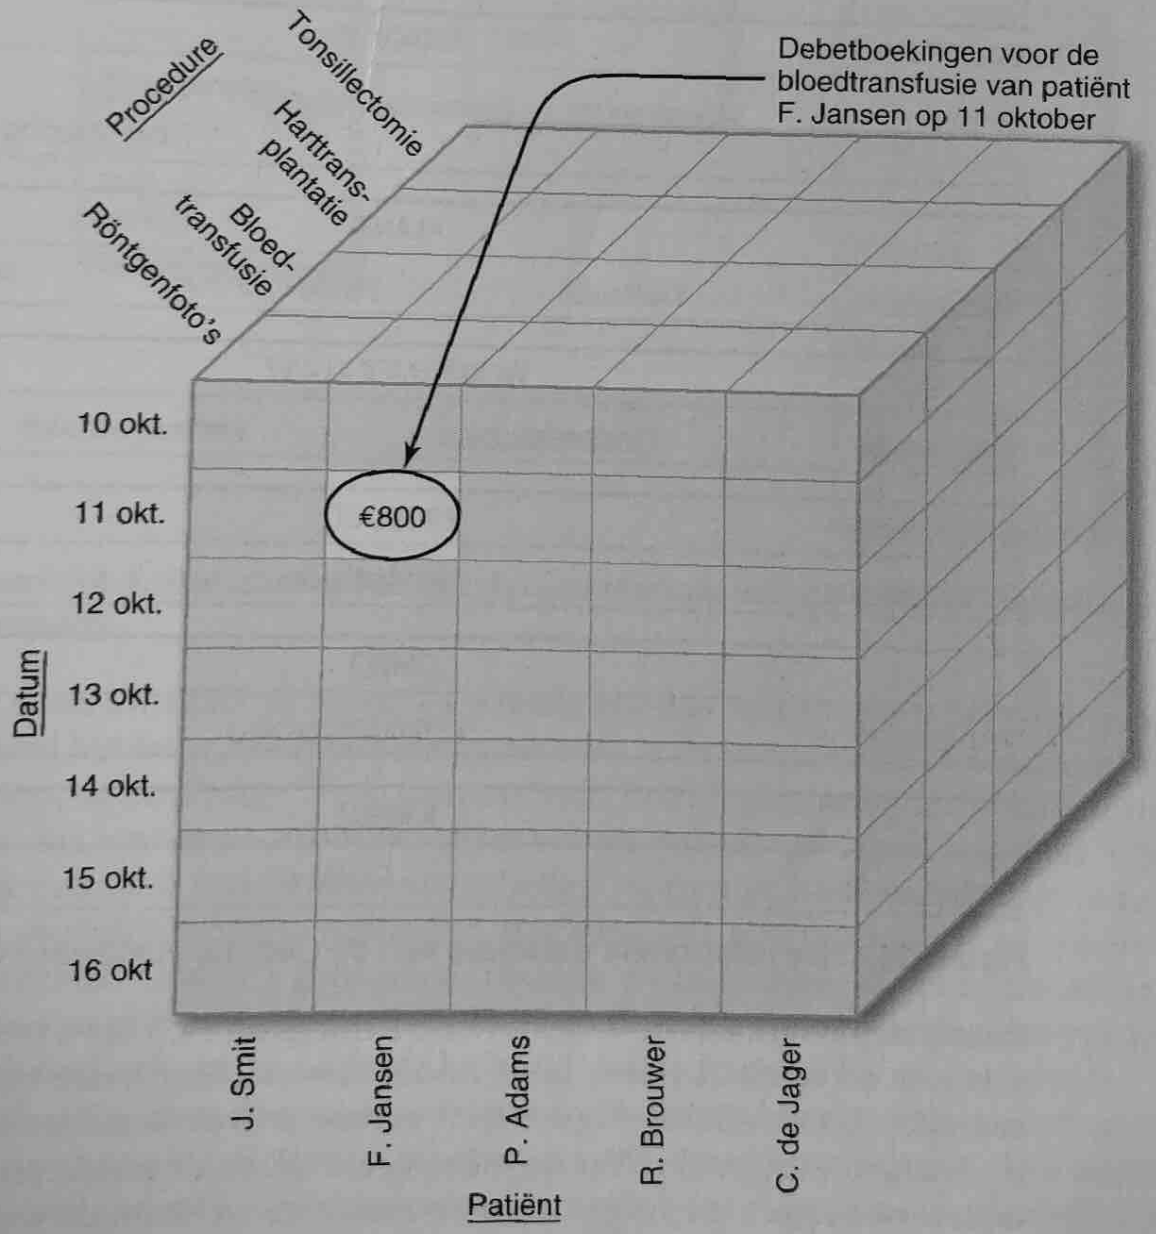
Datawarehousing is inmiddels een breed onderwerp en datawarehouses worden voor allerlei zaken gebruikt. Het hoeft dus geen verrassing te zijn dat er verschillende manieren zijn om datawarehouses te ontwerpen. Alle ontwerpen hebben twee kenmerken met elkaar gemeen: de onderwerpgerichtheid en het historische karakter van de gegevens. Dit wil zeggen dat het datawarehouse (of een groot deel van het datawarehouse) is gebouwd rond een onderwerp en dat het een tijdscomponent heeft. Datawarehouses worden vaak **multidimensionale databases** genoemd omdat aan elke instantie van het onderwerp wordt gerefereerd door een instantie van elk van de **dimensies** of kenmerken van het onderwerp, waarvan tijd er een is. In een ziekenhuissysteem dat gegevens over patiënten en facturen bijhoudt, kan het onderwerp bijvoorbeeld 'debetboekingen' zijn en kunnen de dimensies patiënt, datum, procedure en arts zijn. Als er slechts twee dimensies zijn, bijvoorbeeld de debetboekingen voor bepaalde patiënten op bepaalde datums, zijn deze gemakkelijk te visualiseren op een vel papier (zie figuur 14.3).



Figuur 14.3: Gegevens in een patiëntenvolg- en factureringssysteem met twee dimensies in een ziekenhuis

Als er drie dimensies zijn, bijvoorbeeld de debetboekingen voor bepaalde procedures die op bepaalde datums zijn uitgevoerd op bepaalde patiënten, kunnen de dimensies worden weergegeven als een kubus en nog steeds op papier worden getekend (zie figuur 14.4). Als er vier (of meer) dimensies

zijn, bijvoorbeeld de debetboekingen voor bepaalde procedures die door bepaalde artsen zijn opgedragen voor bepaalde patiënten op bepaalde datums, is wat verbeelding nodig (alhoewel er technieken zijn om dimensies te combineren zodat ze toch visueel in twee of drie dimensies kunnen worden weergegeven). Bepaalde datawarehouseproducten op de markt hebben speciale gegevensstructuren om dergelijke multidimensionale gegevens op te slaan. Er is echter ook veel belangstelling voor de opslag van zulke gegevens in relationele databases. Een manier om multidimensionale gegevens in een relationele gegevensstructuur op te slaan, is met een zogenoemd **sterschema**. De term is afkomstig van het visuele ontwerp waarin het onderwerp in het midden staat en de dimensies om het onderwerp heen uitwaaieren als de stralen van een ster. Zoals eerder is gezegd, heeft Smith & Nephew een datawarehouse met een sterschema. Dit geldt ook voor het grootste gedeelte van de datawarehouseomgeving van Hilton Hotels.



Figuur 14.4: Gegevens in een patiëntenvolg- en factureringssysteem met drie dimensies in een ziekenhuis

14.3.2 Datawarehouse van de General Hardware Company

Figuur 14.5 is een herhaling van de relationele database van General Hardware en figuur 14.6 geeft een sterschema weer voor de General Hardware Company, met OMZET als onderwerp. Sterschema's hebben een 'feitentabel', die het 'onderwerp' van het datawarehouse vertegenwoordigt, en meerdere 'dimensietabellen'. In figuur 14.6 is OMZET de feitentabel en zijn VERKOPER, PRODUCT en TIJDSPERIODE de dimensietabellen. De dimensietabellen maken het mogelijk de gegevens in de feitentabel vanuit verschillende gezichtspunten te bestuderen. Er is een een-op-veel-relatie tussen de entiteit van elke dimensietabel en de entiteit van de feitentabel. De een-kant van de relatie is altijd de dimensietabel, en de veel-kant van de relatie is altijd de feitentabel. Voor een bepaalde verkoper zijn er veel omzetrecords, maar elk omzetrecord hoort bij slechts één verkoper. Hetzelfde geldt voor producten en tijdsperioden.

VERKOPER				
Verkopernummer	Verkopernaam	Commissiepercentage	Jaar van indiensttreding	Kamernummer

KLANT			
Klantnummer	Klantnaam	Verkopernummer	Plaats hoofdkantoor

WERKNEMER KLANT			
Klantnummer	Personeelsnummer	Werknemersnaam	Titel

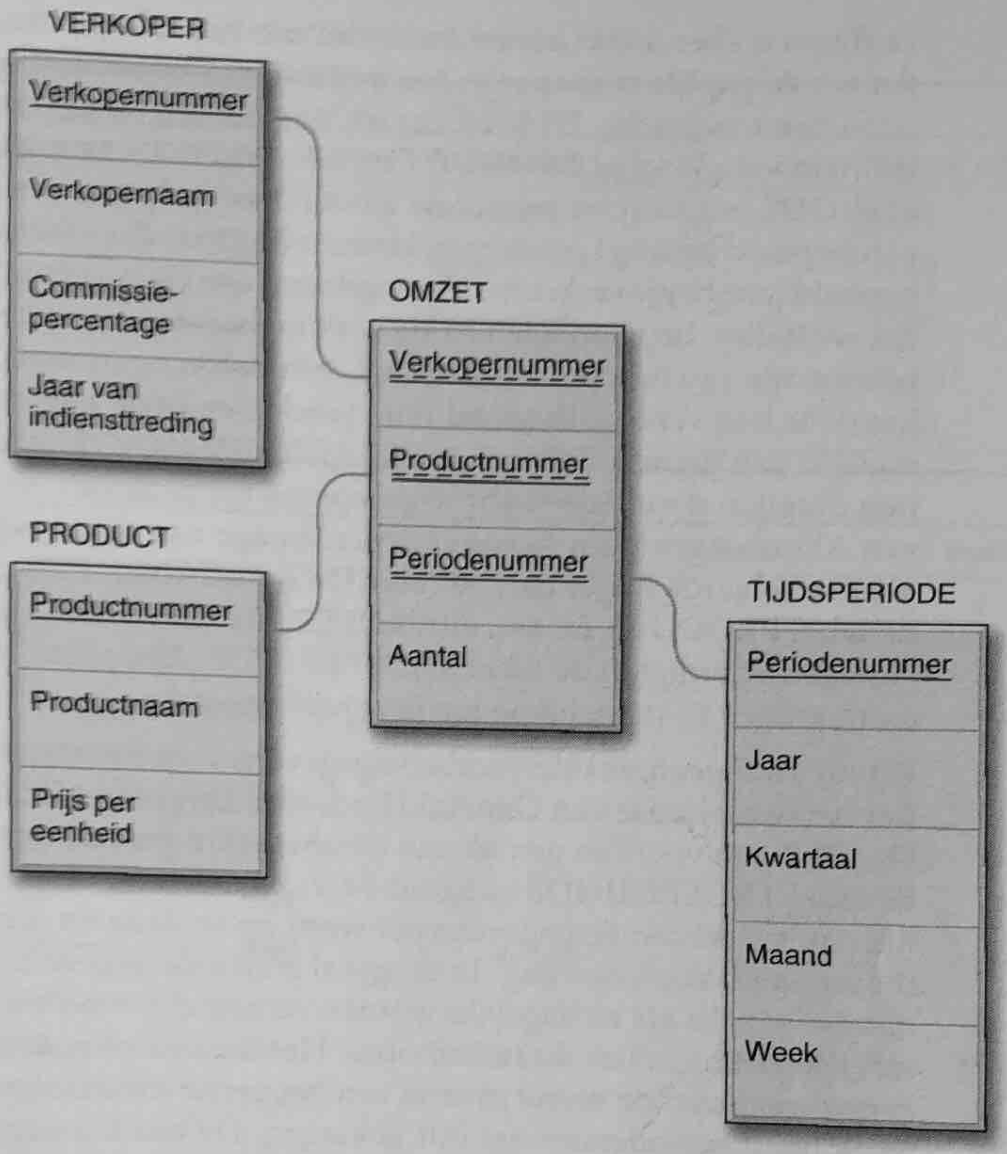
PRODUCT		
Productnummer	Productnaam	Prijs per eenheid

OMZET		
Verkopernummer	Productnummer	Aantal

KAMER		
Kamernummer	Telefoon	Grootte

Figuur 14.5: De relationele database van de General Hardware Company

Raadpleeg nogmaals de tabel OMZET in figuur 14.5 als u beter wilt begrijpen hoe dit werkt. In deze tabel houdt General Hardware bij hoeveel stuks van elk product elke verkoper heeft verkocht in *de recentste* tijdsperiode, zeg in de afgelopen week. Wat moeten we nu doen als we de verkoopgegevens willen vastleggen en volgen voor de recentste week en de week daarvoor en de week daarvoor, enzovoort, mogelijk tot vijf of tien jaar terug? Dit is de beschrijving van een datawarehouse. De tabel OMZET in het sterschema van figuur 14.6 geeft de verkoopgegevens per verkoper en product weer, maar met een nieuw element erbij: tijd. Deze tabel geeft het aantal stuks van elk product weer dat elke verkoper in elke opgeslagen tijdsperiode heeft verkocht.



Figuur 14.6: Sterschema van het datawarehouse van de General Hardware Company

De tabel OMZET in figuur 14.6 moet als elke relationele tabel een primaire sleutel hebben. Zoals u in de figuur ziet, is de primaire sleutel de combinatie van de attributen Verkopernummer, Productnummer en Periodenummer. Elk van deze attributen dient echter ook als refererende sleutel. Elk leidt naar een van de dimensietabellen. Sommige historische informatie kan mogelijk worden verkregen met alleen de feitentabel. Als we alleen de feitentabel OMZET gebruiken, zouden we bijvoorbeeld het totale aantal stuks van een bepaald product kunnen bepalen dat een bepaalde verkoper heeft verkocht gedurende de hele tijd dat de historische omzetrecords worden bijgehouden, aangenomen dat we zowel het productnummer van het product als het verkopernummer van de verkoper kennen. We zouden daarvoor gewoon de waarden van het attribuut Aantal in alle records voor die verkoper en dat product in de tabel OMZET bij elkaar optellen. De dimensietabellen bieden echter geheel nieuwe mogelijkheden! Als we ons bijvoorbeeld concentreren op het attribuut Jaar van de tabel TIJDSPERIODE en gebruikmaken van het feit dat deze tabel via een refererende sleutel is verbonden met de tabel OMZET, zouden we onze zoekactie kunnen

verfijnen en het totale aantal stuks van een bepaald product kunnen bepalen dat een bepaalde verkoper in een bepaald jaar of in een bepaald bereik van jaren heeft verkocht. En wanneer we ons richten op het attribuut Prijs per eenheid van de tabel PRODUCT en het attribuut Jaar van de tabel TIJDSPERIODE, zouden we het totale aantal dure (prijs per eenheid hoger dan een bepaald bedrag) producten kunnen bepalen dat elke verkoper in een bepaald jaar heeft verkocht. Veronderstel, om dit nog concreter te maken, dat we willen bepalen wie van de verkopers die momenteel een commissiepercentage van tien procent hebben, een beloning moeten krijgen vanwege het door hen verkochte aantal dure producten in de afgelopen drie jaar. We zouden dan de waarden van Aantal in de records in de tabel OMZET kunnen optellen door de records te groeperen op basis van een attribuutwaarde van 10 in het attribuut Commissiepercentage van de tabel VERKOPER, een attribuutwaarde hoger dan 50 (euro) in het attribuut Prijs per eenheid van de tabel PRODUCT en een attribuut Jaar dat elk van de afgelopen drie jaren vertegenwoordigt in de tabel TIJDSPERIODE. Het aantal verschillende combinaties en mogelijkheden is vrijwel oneindig.

Figuur 14.7 geeft enkele voorbeeldgegevens voor het sterschema van het datawarehouse van General Hardware. De getoonde rijen in de tabel OMZET zijn voor het gemak aan de linkerkant genummerd. Kijk eens naar de tabel TIJDSPERIODE in figuur 14.7. Allereerst is uit deze tabel duidelijk dat is besloten de gegevens per week op te slaan en niet per kleinere tijdseenheid zoals een dag. In dit geval zullen de gegevens in de transactiedatabase, zelfs als ze dagelijks worden verzameld, worden geaggregeerd tot weekgegevens in het datawarehouse. Het datawarehouse is begonnen in de eerste week van de eerste maand van het eerste kwartaal van 1997 en deze week heeft periodenummer 001 gekregen. De week daarna heeft periodenummer 002 gekregen en zo verder tot de laatst opgeslagen week. Bekijk nu de tabel OMZET. Rij 10 geeft aan dat verkoper 137 in periode 103 in totaal 59 eenheden van product 24013 heeft verkocht, wat volgens de tabel TIJDSPERIODE de derde week van de derde maand van het vierde kwartaal van 1998 was (dat wil zeggen de derde week van december 1998). Rij 17 van de tabel OMZET geeft aan dat verkoper 204 in periode 331, de derde week van mei 2003, 44 stuks van product 16386 heeft verkocht. Wanneer u rij 1 tot en met rij 20 van de tabel OMZET bekijkt, ziet u de historische aard van de gegevens en dat de tijd gestaag voortschrijdt naarmate het periodenummer oploopt van periode 001 in de eerste paar records naar periode 331 in de laatste batch van records.

VERKOPER

Verkopernummer	Verkopernaam	Commissiepercentage	Jaar van indienst-treding
137	Baker	10	1995
186	Adams	15	2001
204	Dickens	10	1998
361	Carlyle	20	2001

Zie vervolg

vervolg

PRODUCT

Productnummer	Productnaam	Prijs per eenheid
16386	Moersleutel	12,95
19440	Hamer	17,50
21765	Boormachine	32,99
24013	Zaag	26,25
26722	Combinatietang	11,50

TIJDSPERIODE

Periodenummer	Jaar	Kwartaal	Maand	Week
001	1997	1	1	1
002	1997	1	1	2
003	1997	1	1	3
...				
101	1998	4	3	1
102	1998	4	3	2
103	1998	4	3	3
104	1998	4	3	4
...				
329	2003	2	2	1
330	2003	2	2	2
331	2003	2	2	3

OMZET

	Verkopernummer	Productnummer	Periodenummer	Aantal
1	137	16386	001	57
2	137	24013	001	129
3	137	16386	002	24
4	137	24013	002	30
	...			
5	137	16386	102	85
6	137	24013	102	36
7	204	16386	102	111
8	204	24013	102	44
	...			
9	137	16386	103	47
10	137	24013	103	59
11	204	16386	103	13
12	204	24013	103	106

Zie vervolg

vervolg

13	137	16386	331	63
14	137	24013	331	30
15	186	16386	331	25
16	186	24013	331	16
17	204	16386	331	44
18	204	24013	331	107
19	361	16386	331	18
20	361	24013	331	59

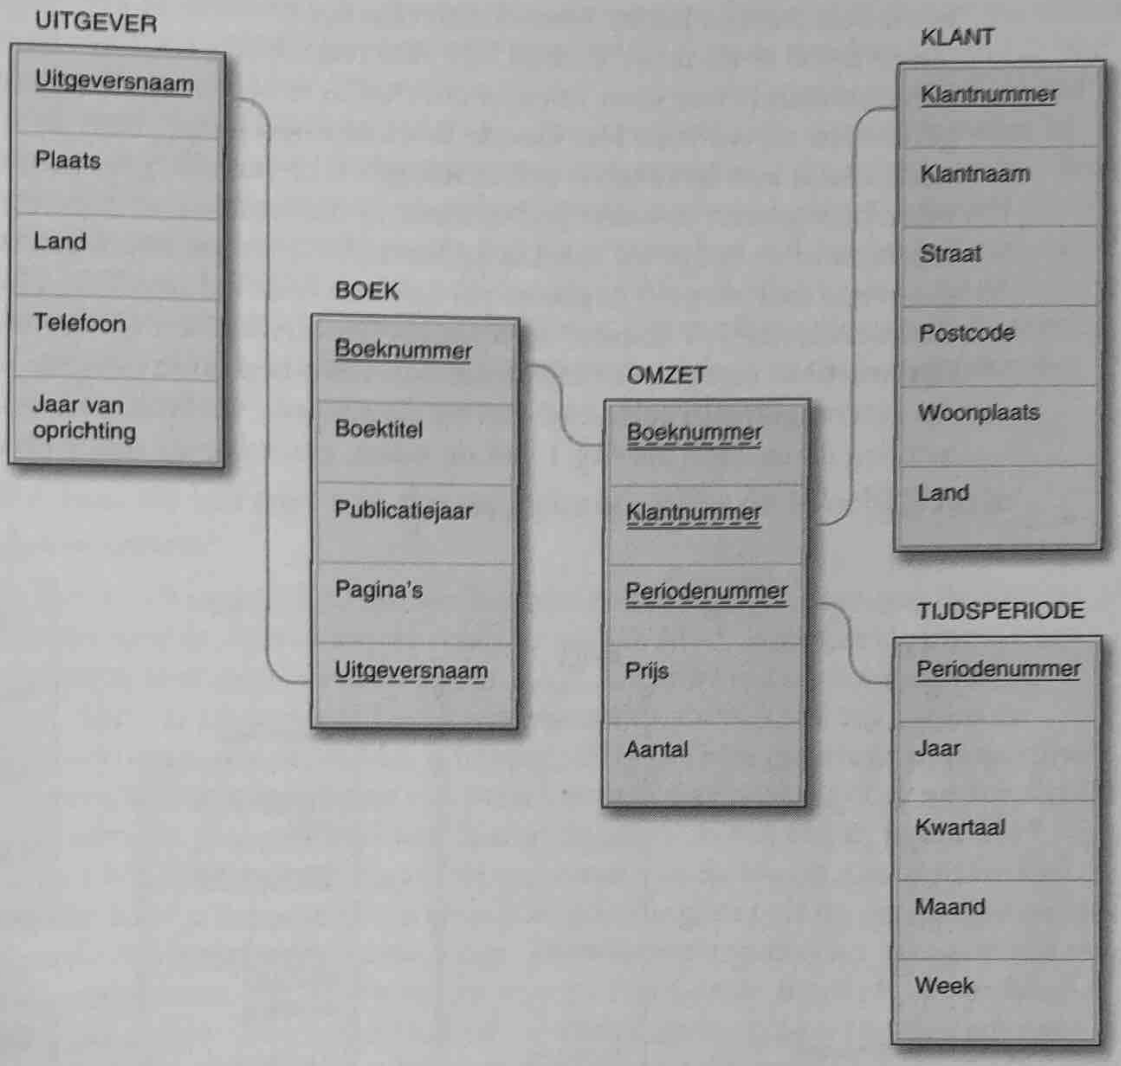
Figuur 14.7: Voorbeeldgegevens voor het datawarehouse van de General Hardware Company

14.3.3 Datawarehouse voor de boekhandels van Het Goede Boek

Hebben de boekhandels van Het Goede Boek een datawarehouse nodig? Dit is eigenlijk een heel goede vraag. Het antwoord zal een aantal belangrijke punten over datawarehouses duidelijk maken. Op het eerste gezicht lijkt het antwoord te zijn dat Het Goede Boek mogelijk helemaal geen datawarehouse nodig heeft. De verkoopgegevens in de transactiedatabase van Het Goede Boek *hebben immers al een datumattribuut*, zoals de tabel OMZET in figuur 5.16 laat zien. De transactiedatabase van Het Goede Boek lijkt dus al historisch te zijn! Het Goede Boek heeft echter om twee redenen toch een datawarehouse nodig. De eerste reden is dat de transactiedatabase van Het Goede Boek misschien nog best redelijk presteert als hij alleen de gegevens van de laatste paar maanden bevat, maar dat de prestaties tot een onaanvaardbaar niveau zouden dalen als we er de gegevens van tien jaar in zouden bewaren. De andere reden is dat voor het soort managementbeslissingen waarvoor historische verkoopgegevens over een langere termijn nodig zijn, geen dagelijkse gegevens nodig zijn. Geaggregeerde gegevens op weekniveau voldoen prima voor de besluitvorming van Het Goede Boek. Als de gegevens op weekbasis worden opgeslagen, bespaart dat heel wat tijd vergeleken met de situatie waarin de gegevens op dagbasis worden opgeslagen en voor elke query veel meer gegevens moeten worden opgehaald en opgeteld.

Figuur 14.8 geeft het sterschema van het datawarehouse van Het Goede Boek weer. De feitentabel is de tabel OMZET en elk van de records in deze tabel geeft aan hoeveel exemplaren een bepaalde klant in een bepaalde week van een bepaald boek heeft gekocht (de week is hier weer de fijnste tijdseenheid), almede de prijs die de klant per boek heeft betaald. Dit heeft overigens alleen zin als het bedrijf de prijs van een boek niet halverwege de week wijzigt, want elke rij in de tabel OMZET heeft slechts ruimte voor één prijs bij het totale aantal stuks van dat boek dat de klant in kwestie in die week heeft gekocht. Het ontwerp in figuur 14.8 heeft een element waardoor het ook een **sneeuwvlokontwerp** (*snowflake design*) is. Een van de dimensietabellen, BOEK, leidt ook nog naar een andere dimensietabel, UITGEVER. Overeenkomstig de rest van het sterschema is de sneeuwvlokrelatie een een-op-veel-relatie, 'naar binnen gericht' naar het centrum van

de ster: een uitgever geeft veel boeken uit, maar een boek is slechts verbonden met slechts één uitgever.

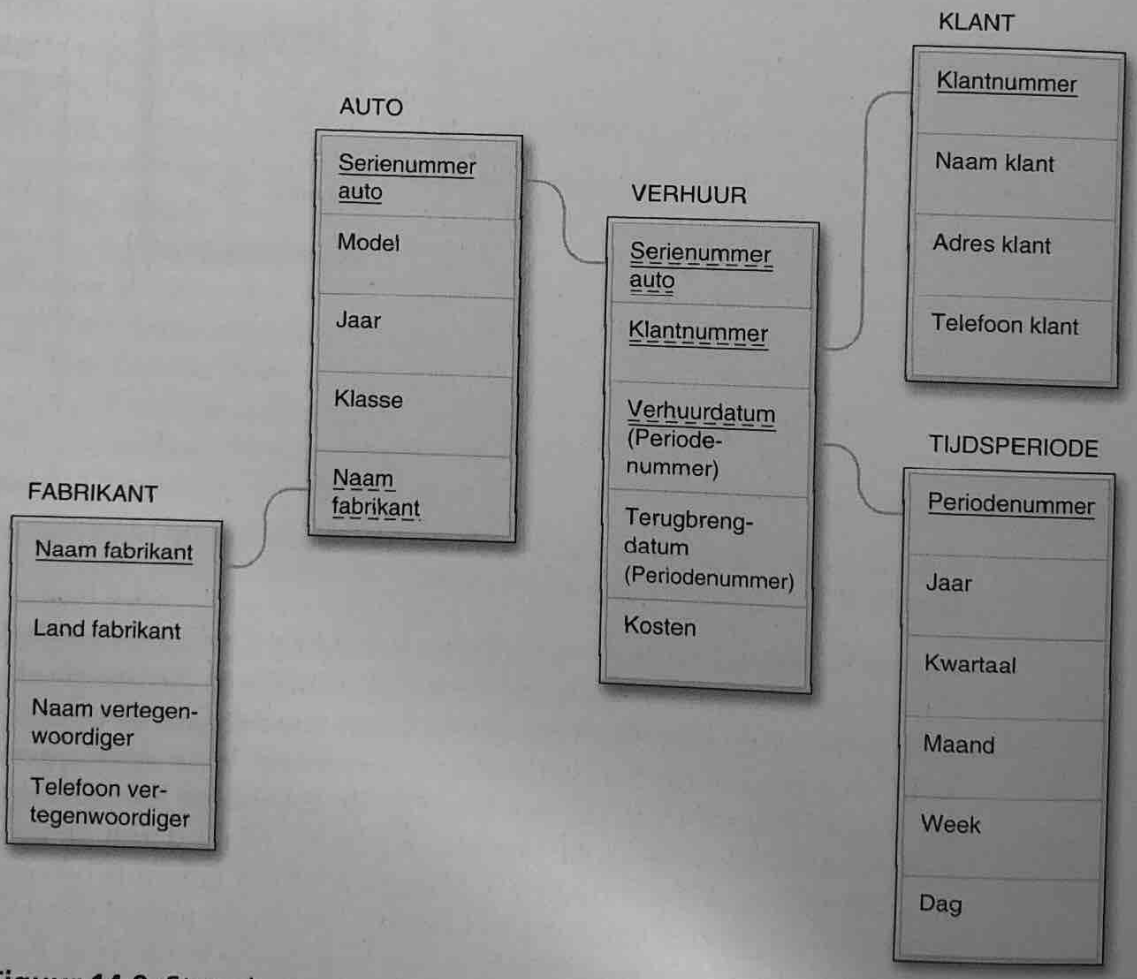


Figuur 14.8: Sterschema van het datawarehouse van de boekhandels van Het Goede Boek met sneeuwvlokelement

Om te bepalen hoeveel exemplaren van *Moby Dick* Het Goede Boek moet bestellen voor de kerstperiode voor zijn winkels in Amsterdam, kan Het Goede Boek nagaan hoeveel exemplaren van *Moby Dick* er de afgelopen vijf jaren in Amsterdam zijn verkocht in december. Voor deze query zijn het attribuut Boektitel van de tabel BOEK, de attributen Woonplaats en Land van de tabel KLANT en de attributen Jaar en Maand van de tabel TIJDSPERIODE nodig. Als het bedrijf wil bepalen of het zinvol is om meer winkels te openen in Rotterdam, zou het bedrijf het totale aantal van alle verkochte boeken in de afgelopen vijf jaar in alle bestaande winkels in Rotterdam kunnen optellen. Door het sneeuwvlokelement kunnen nog veel meer queries worden geformuleerd. Met het attribuut Land van de tabel UITGEVER, het attribuut Land van de tabel KLANT en de attributen Kwartaal en Jaar van de tabel TIJDSPERIODE zou het bedrijf het totale aantal boeken kunnen bepalen dat in Brazilië is uitgegeven en door klanten in België in het tweede kwartaal van 1999 is gekocht.

14.3.4 Datawarehouse van Lucky Rent-A-Car

Net als de transactiedatabase van de boekhandels van Het Goede Boek heeft ook die van Lucky Rent-A-Car (zie figuur 5.18) al een datumattribuut (twee zelfs) in de tabel VERHUUR. De redenering voor het creëren van een datawarehouse voor Lucky Rent-A-Car is op dezelfde argumenten gebaseerd als we voor Het Goede Boek hebben besproken: de transactiedatabase zou bezwijken onder het gewicht van alle gegevens als we de verhuurgegevens van tien jaar of meer in de database zouden opslaan. Interessant in het geval van Lucky Rent-A-Car is dat het datawarehouse de gegevens toch nog op dagbasis zal opslaan (wat zal resulteren in een *enorm* datawarehouse). Waarom? In de autoverhuurwereld is het belangrijk dat kan worden nagegaan of bijvoorbeeld in een bepaalde periode meer auto's op zaterdagen zijn verhuurd dan op dinsdagen. Veronderstel dat we de zondag aanduiden als dag 1 van de week, zaterdag als dag 7 en dinsdag als dag 3.



Figuur 14.9: Sterschema van het datawarehouse van Lucky Rent-A-Car met sneeuwvlokelement

Figuur 14.9 geeft het sterschema van het datawarehouse van Lucky Rent-A-Car weer. De feitentabel is de tabel VERHUUR. In dit geval bevat de feitentabel *geen* geaggregeerde gegevens. In het datawarehouse wordt elke verhuurtransactie vastgelegd voor het nageslacht. Dit datawarehouse heeft

een sneeuwvlokelement doordat de dimensietabel AUTO naar buiten gericht is verbonden met de tabel FABRIKANT. Dit datawarehouse heeft rijke querymogelijkheden. Lucky zou kunnen vragen hoeveel mid-size auto's van Opel (het attribuut Klasse van de tabel AUTO) in de weekenden in juli van de afgelopen vijf jaar zijn verhuurd. Als Lucky voor marketingdoeleinden wil bepalen wie zijn beste klanten zijn, zou Lucky de klanten kunnen bepalen (en een naam- en adreslijst van hen opstellen) die minstens drie keer een full-size auto voor minstens een week per keer hebben gehuurd in de wintermaanden van elk van de afgelopen drie jaar. Of het bedrijf zou met het attribuut Land fabrikant van de tabel FABRIKANT in de sneeuwvlok de inkomsten kunnen bepalen (op basis van het attribuut Kosten in de tabel VERHUUR) die het bedrijf heeft gegenereerd door in de zomervakanties van de afgelopen acht jaar Japanse auto's te verhuren.

14.3.5 En hoe zit het met een datawarehouse voor de World Music Association?

Is het u ook opgevallen dat we het niet hebben gehad over een datawarehouse voor de World Music Association (WMA), waarvan de transactiedatabase is weergegeven in figuur 5.17? Als er zo'n datawarehouse zou zijn, zou het onderwerp hoogstwaarschijnlijk OPNAME zijn, want de kernactiviteit van de WMA is in feite dat de WMA gegevens bijhoudt over de verschillende opnamen van verschillende composities door verschillende orkesten. Er is al een attribuut Jaar in de tabel OPNAME in figuur 5.17. In deze zin hebben de belangrijkste gegevens van de transactiedatabase van de World Music Association al een tijdaanduiding, net als de gegevens van Het Goede Boek en Lucky Rent-A-Car. We hebben argumenten aangevoerd voor het creëren van een datawarehouse voor Het Goede Boek en Lucky Rent-A-Car, maar hoe zit het met de WMA? Op de eerste plaats zijn de gegevens van de WMA *in essentie* al **historisch** van aard. We kunnen net zo geïnteresseerd zijn in een opname die vijftig jaar geleden is gemaakt als in een opname van vorig jaar. Op de tweede plaats is de hoeveelheid gegevens in een transactiedatabase als die van de WMA door de aard van de gegevens veel kleiner dan in een transactiedatabase als die van Het Goede Boek of Lucky. De laatste twee transactiedatabases bevatten dagelijkse verkooprecords van bedrijven waar dagelijks veel transacties plaatsvinden. Zelfs wereldwijd is het aantal opnamen dat orkesten maken, in vergelijking veel kleiner. De conclusie is dus dat de WMA geen datawarehouse nodig heeft omdat het datawarehouse van de WMA er min of meer hetzelfde uit zou zien als de transactiedatabase van de WMA en omdat de hoeveelheid (historische) gegevens in de transactiedatabase van de WMA hanteerbaar is.

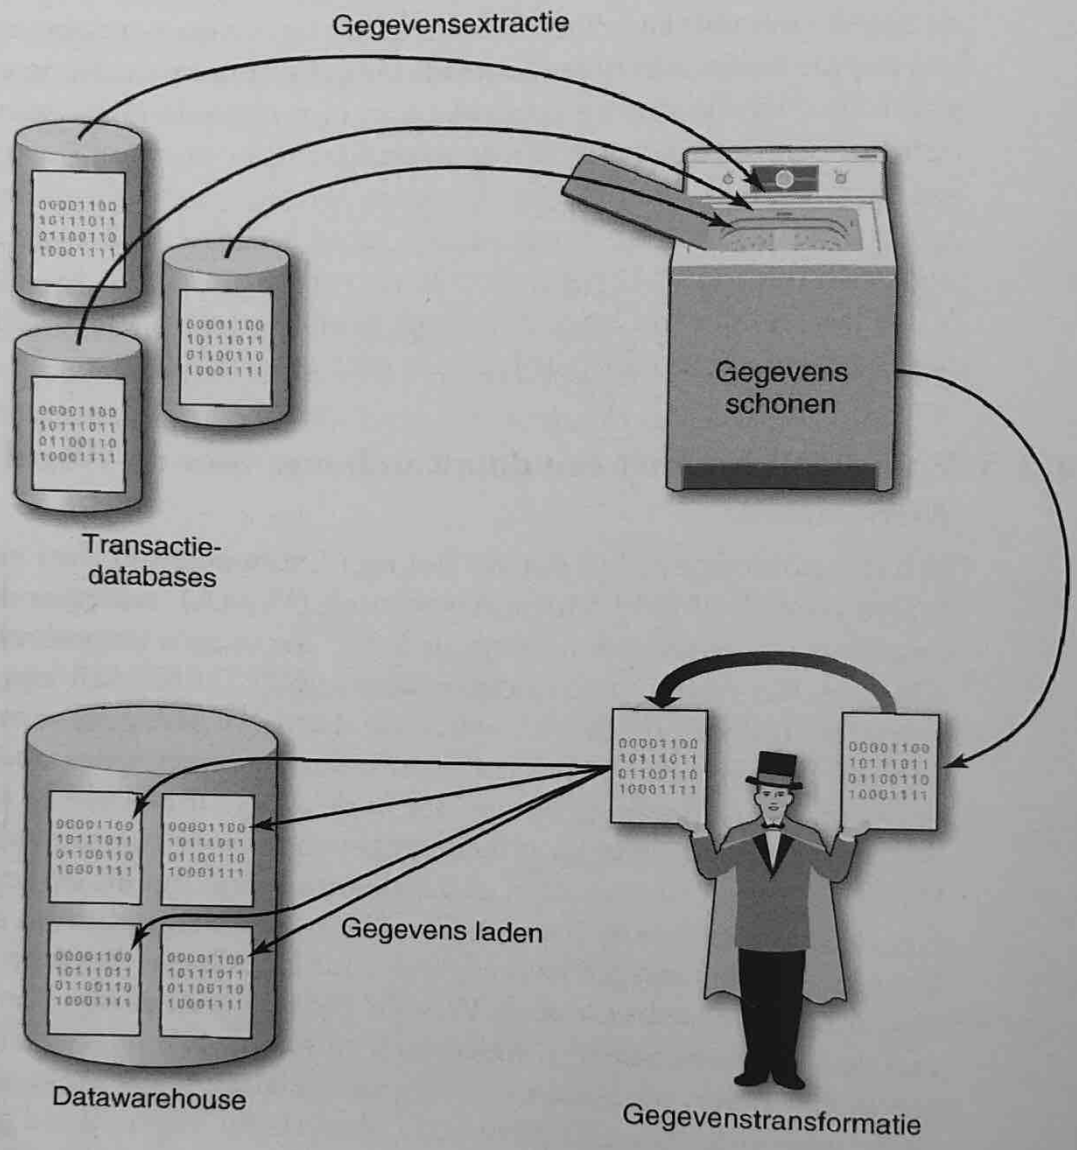
14.4 Een datawarehouse bouwen

Wanneer het datawarehouse eenmaal is ontworpen, vindt het eigenlijke bouwen van het datawarehouse plaats in vier stappen (zie figuur 14.10):

- **gegevens extraheren**;
- **gegevens schonen**;

- **gegevens transformeren;**
- **gegevens laden.**

We bespreken de vier stappen een voor een.



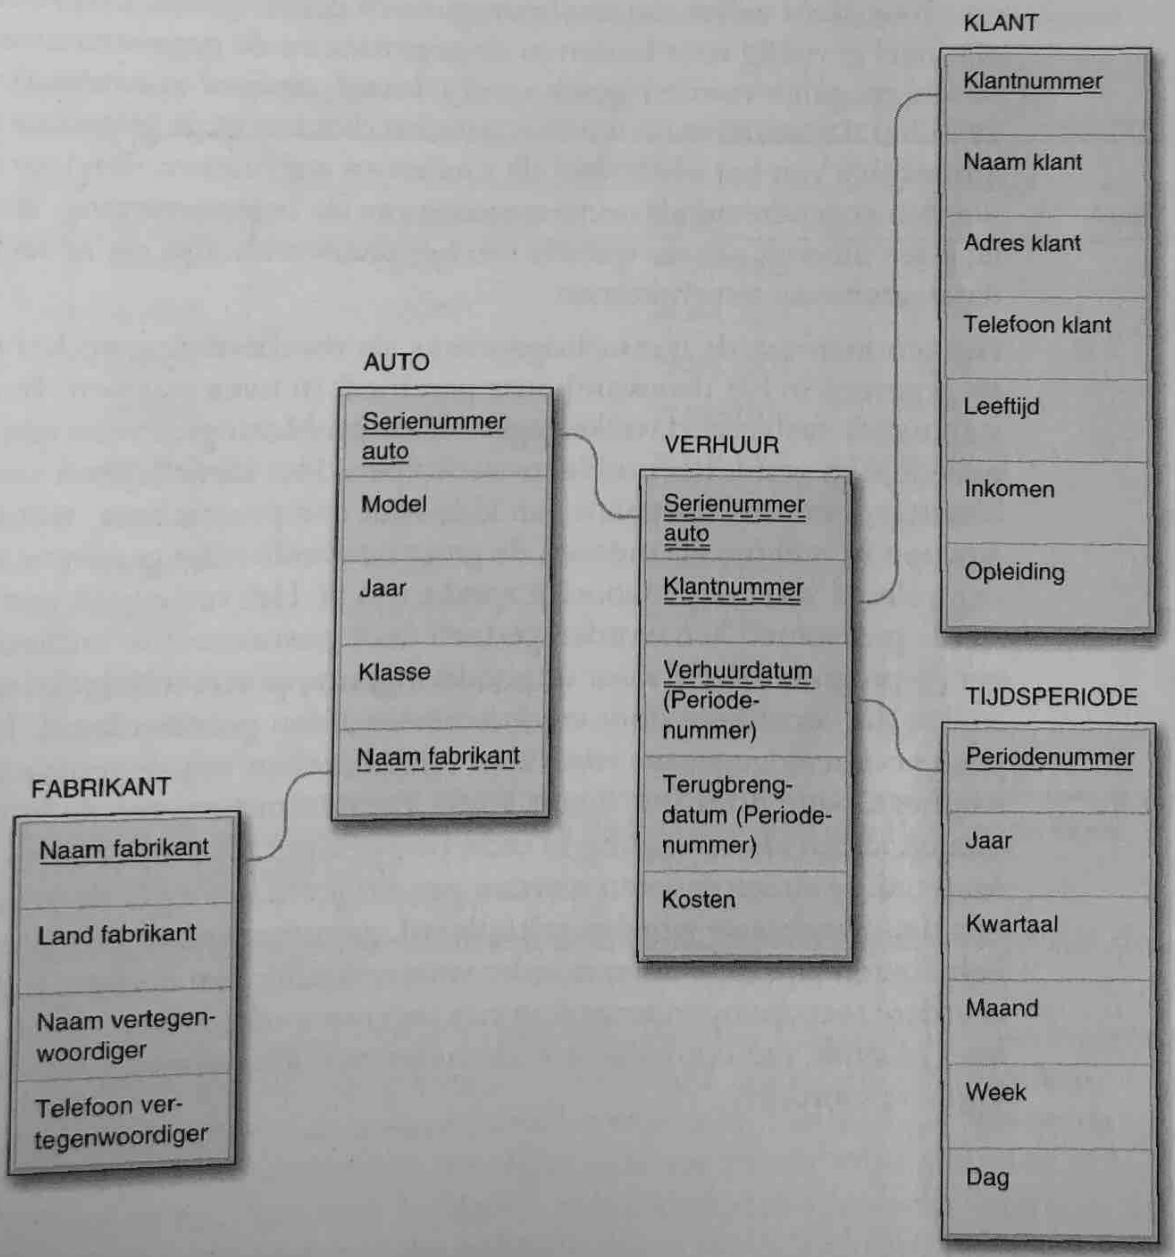
Figuur 14.10: De vier stappen voor het bouwen van een datawarehouse

14.4.1 Gegevens extraheren

Gegevensextractie is het kopiëren van de gegevens vanuit de transactiedatabases als voorbereiding om ze daarna in het datawarehouse te laden. Er zijn enkele belangrijke zaken die u hier moet onthouden. Een daarvan is dat gegevensextractie niet iets eenmaligs is. Natuurlijk moeten er een eerste keer gegevens uit de transactiedatabases worden geëxtraheerd wanneer het datawarehouse net is gebouwd, maar daarna is het een doorgaand proces dat regelmatig moet worden uitgevoerd (bijvoorbeeld dagelijks, wekelijks of maandelijks) om de meest recente dag-, week- of maandgegevens aan het datawarehouse toe te voegen. Een ander punt is dat de gegevens waarschijnlijk afkomstig zullen zijn uit verschillende transactiedatabases. Bepaalde gegevens

(dat wil zeggen, niet noodzakelijk alle gegevens) in elke transactiedatabase worden gekopieerd en samengevoegd tot het datawarehouse. Er zijn onderweg enkele valkuilen waar u rekening mee moet houden, zoals dat de unieke identifier waarmee de werknemers worden aangeduid in de ene transactiedatabase Personeelsnummer en in de andere transactiedatabase Serienummer kan heten. Evenzo kan de attribuutnaam Serienummer in de ene database het serienummer van een werknemer zijn, terwijl het in een andere database het serienummer van een voltooid product is.

Een deel van de gegevens die in dit proces worden ingevoerd, kan van buiten het bedrijf komen. Er zijn bijvoorbeeld bedrijven die demografische gegevens over mensen verkopen aan bedrijven die deze gegevens vervolgens voor marketingdoeleinden gebruiken. Dit proces wordt **gegevensverrijking** (*data enrichment*) genoemd. Figuur 14.11 geeft verrijkingsgegevens weer die zijn toegevoegd aan de dimensietabel KLANT in het datawarehouse van Lucky Rent-A-Car uit figuur 14.9.



Figuur 14.11: Ontwerp van het datawarehouse van Lucky Rent-A-Car met verrijkingsgegevens toegevoegd aan de tabel KLANT

Tijdens het verrijkingsproces zijn gegevens over de leeftijd, het inkomen en de opleiding toegevoegd, die waarschijnlijk van een externe gegevensbron afkomstig zijn. Lucky kan deze gegevens gebruiken om onder klanten die in bepaalde demografische categorieën vallen, reclame te maken voor het huren van bepaalde soorten auto's. In de paragraaf over data-mining (paragraaf 14.5.2) gaan we hier nader op in.

14.4.2 Gegevens schonen

Transactiegegevens kunnen allerlei fouten bevatten, die wel of niet van invloed kunnen zijn op de toepassingen die van de gegevens gebruikmaken. Als de naam van een klant bijvoorbeeld verkeerd is gespeld, maar de posterijen toch kunnen achterhalen bij wie ze iets moeten bezorgen, kan het goed zijn dat niemand de moeite neemt om de fout in de klanttabel van het bedrijf te corrigeren. Aan de andere kant zal een klant het waarschijnlijk in de gaten hebben wanneer het totaalbedrag van een nota veel te hoog is en zal de klant willen dat het bedrag wordt gecorrigeerd. Datawarehouses zijn heel gevoelig voor fouten in de gegevens en de gegevens moeten dus zoveel mogelijk worden 'geschoond' (*cleaned*, *cleansed* of *scrubbed*) voordat ze in het datawarehouse worden geladen. Fouten in de gegevens sturen, afhankelijk van het soort fout, de totalen en statistieken die door de queries worden gegenereerd als ondersteuning van de besluitvorming, in de war en doen afbreuk aan de waarde van het datawarehouse als ze toch in het datawarehouse terechtkomen.

Het schonen van de transactiegegevens als voorbereiding op het laden van de gegevens in het datawarehouse geschiedt in twee stappen. In de eerste stap wordt vastgesteld welke gegevens de probleemgegevens zijn en in de tweede stap wordt het probleem verholpen. Het identificeren van de probleemgegevens is doorgaans een klus voor een programma, want het kost gewoon te veel tijd als mensen de grote hoeveelheden gegevens zouden controleren waar tegenwoordig sprake van is. Het verhelpen van de vastgestelde problemen kan worden gedaan door geavanceerde artificial-intelligence-programma's of door uitzonderingenrapporten (*exception reports*) op te stellen die vervolgens door werknemers worden gecontroleerd. Figuur 14.12 geeft voorbeeldgegevens weer voor twee tabellen van de transactiedatabase van het Goede Boek (zie figuur 5.16). De rijnummers aan de linkerkant dienen alleen als verwijzing in deze bespreking. Elke tabel bevat meerdere fouten die zouden moeten worden gecorrigeerd wanneer de gegevens naar een datawarehouse worden gekopieerd, geïntegreerd en geaggregeerd. Enkele fouten zijn misschien minder waarschijnlijk dan andere in de geavanceerdere toepassingenomgeving van tegenwoordig, maar samen zijn ze toch heel geschikt om duidelijk te maken dat zich allerlei mogelijke problemen kunnen voordoen.

(a) Tabel KLANT

	Klant-nummer	Klantnaam	Straat	Postcode	Woonplaats	Land
1	02487	Meeuws	Kroonsingel 306	6581 BT		Nederland
2	03185	Groen	Hoofdstraat 345	6661 KX	Elst	Nederland
3	03480	Theunissen	Olmenstraat 50	5541 BR	Oeffelt	Nederland
4	06837	Stevens	876 Leslie Lane		Raleigh, NC	USA
5	08362	Adams	1200 Wallaby Street		Brisbane	Australië
6	12739	Groen	Hoofdstraat 345	3921 AZ	Elst	Nederland
7	13848	Lucas	742 Avenue Louise		Brussel	België
8	15367	Theunessen	Olmenstraat 50	5441 BR	Oeffelt	Nederland
9	15933	Chang	48 Maple Avenue		Toronto, ON	Canada
10	18575	Smit	Malderburchstraat 390	6581 AK	Columbus	Nederland
11	21359	Sanchez	660 Ave. Bolivar		Santiago	Chili

(b) Tabel OMZET

	Boeknummer	Klantnummer	Datum	Prijs	Aantal
1	426478	03480	19 mei 2003	32,99	1
2	077656	18575	19 mei 2003	19,95	21
3	365905	06837	19 mei 2003	24,99	3
4	645688	21359	20 mei 2003	49,50	1
5	474640	15367	24 mei 2003	3200,99	1
6	426478	08362	3 juni 2003	32,99	2
7	276432	03480	4 juni 2003	30,00	1
8	365905	12738	4 juni 2003	24,99	1
9	276432	06837	5 juni 2003	30,00	5
10	327467	18575	12 juni 2003	-32,99	2
11	426478	06837	15 juni 2003	32,99	1

Figuur 14.12: Voorbeeldgegevens van de boekhandels van Het Goede Boek voordat ze zijn geschoond

Vier fouten of mogelijke fouten in de tabel KLANT in figuur 14.12 zijn de volgende:

- *Ontbrekende gegevens:* In rij 1 heeft het attribuut Woonplaats geen waarde. Mogelijk kan een programma in een online telefoonboek opzoeken in welke plaats een zekere Meeuws woont op Kroonsingel 306 en de woonplaats automatisch invoegen in het attribuut Woonplaats in rij 1. Dit type fout kan zich natuurlijk ook voordoen in gegevens waarvoor het ontbrekende gegeven niet online kan worden opgezocht.

- *Twijfelachtige gegevens:* De rijen 2 en 6, die een verschillend klantnummer bevatten, hebben wel allebei betrekking op een klant met de naam Groen die op Hoofdstraat 345 in Elst woont. De ene plaats is echter Elst in de provincie Utrecht en de andere Elst in de provincie Gelderland. De vraag is of het hier echt om verschillende mensen gaat die toevallig dezelfde naam en hetzelfde huisadres hebben in twee verschillende steden of dat het om één persoon gaat en een van de postcodes niet klopt en er slechts één klantnummer had moeten zijn.
- *Mogelijke typefouten:* De rijen 3 en 8 hebben verschillende klantnummers maar zijn verder volkomen identiek, op één letter verschil in de naam van de klant na, 'Theunissen' versus 'Theunessen'. Verwijzen beide rijen naar dezelfde persoon? Laten we ten behoeve van het betoog veronderstellen dat er geen online telefoonboek is, maar alleen een lijst van onroerend goed waarin staat aangegeven welke adressen bij eengezinswoningen of appartementen horen en welke bij onzelfstandige woonruimten. Er zou dan een programma kunnen worden ontwikkeld dat aanneemt dat er sprake is van een typefout en dat de twee records naar dezelfde persoon verwijzen als het adres betrekking heeft op een eengezinswoning of appartement. Als het adres aan de andere kant onzelfstandige woonruimte betreft, zou het om twee verschillende personen kunnen gaan.
- *Onmogelijke gegevens:* Rij 10 bevat de plaatsnaam Columbus. In Nederland komt deze plaatsnaam niet voor. Dit moet worden opgemerkt en gemarkeerd en vervolgens automatisch of handmatig worden gecorrigeerd.

Ook de tabel VERKOOP in figuur 14.12b bevat vier fouten of mogelijke fouten. De gegevens in deze tabel zijn meer numeriek van aard dan de gegevens in de tabel KLANT:

- *Twijfelachtige gegevens:* Rij 2 geeft aan dat in één transactie eenentwintig exemplaren van een bepaald boek zijn gekocht. Dit is mogelijk, maar niet erg waarschijnlijk. Er kan een programma worden geschreven dat bepaalt of het gegeven zo gelaten wordt of dat het als een uitzondering (*exception*) wordt gemeld, afhankelijk van de vraag of dit aantal waarschijnlijk is, gelet op het type boek in kwestie.
- *Onmogelijke gegevens/gegevens buiten het waardebereik:* Rij 5 geeft aan dat één boek 3.200,99 euro heeft gekost. Dit valt buiten het bereik van mogelijke prijzen voor boeken en moet worden gecorrigeerd op basis van de prijs die in het systeem is opgeslagen voor het boek in kwestie (op basis van het boeknummer) of als uitzondering worden gemeld.
- *Apert onjuiste gegevens:* Het klantnummer in rij 8 is ongeldig. We hebben geen klant met klantnummer 12738, maar we hebben wel een klant met klantnummer 12739 (zie rij 6 van de tabel KLANT in deel (a) van de figuur). Hier moet iemand even naar kijken.
- *Onmogelijke gegevens:* Rij 10 geeft een negatieve prijs voor een boek aan, wat duidelijk niet kan kloppen.

14.4.3 Gegevens transformeren

Wanneer de gegevens uit de transactiedatabases zijn geëxtraheerd, ondergaan ze op weg naar het datawarehouse verschillende soorten **gegevenstransformaties**:

- We hebben het al gehad over het feit dat gegevens uit verschillende transactiedatabases moeten worden samengevoegd tot de tabellen van het datawarehouse. Dit is in feite een van de belangrijkste stappen van het gegevenstransformatieproces.
- In veel gevallen zullen de gegevens worden geaggregeerd wanneer ze worden geëxtraheerd uit de transactiedatabases en worden voorbereid voor het datawarehouse. Dagelijkse transactiegegevens kunnen worden opgeteld tot weekgegevens of maandgegevens en, qua tijdsperiode, als laagste gegevensniveau in het datawarehouse worden opgeslagen.
- De maateenheden die in de verschillende transactiedatabases voor de attributen zijn gebruikt, moeten op één lijn worden gebracht wanneer de attributen worden samengevoegd in de tabellen van het datawarehouse. Dit komt vooral veel voor als een transactiedatabase het metrische systeem gebruikt en een andere database het Engelse systeem. Mijlen en kilometers, Britse ponden en kilo's, gallons en liters moeten allemaal worden geconverteerd om uiteindelijk op dezelfde manier in het datawarehouse te worden weergegeven.
- De gebruikte coderingsschema's voor de attributen in de verschillende transactiedatabases moeten op één lijn worden gebracht wanneer de gegevens worden samengevoegd in de tabellen in het datawarehouse. De staten van de Verenigde Staten kunnen in verschillende databases bijvoorbeeld voluit zijn geschreven, zijn afgekort tot twee letters of zijn aangeduid met een numerieke code van 1 tot en met 50. De landen van de wereld kunnen worden weergegeven door hun volledige naam, door de standaardafkortingen die op voertuigen staan of met een numerieke code. Een ander belangrijk aandachtspunt zijn de verschillende manieren waarop datums kunnen worden opgeslagen.
- Soms worden de waarden van verschillende attributen in transactiedatabases gecombineerd tot één attribuut in het datawarehouse of vindt juist het tegenovergestelde proces plaats en wordt een attribuut in meerdere delen gesplitst. Hierbij valt te denken aan de voornaam en achternaam van werknemers of klanten.

14.4.4 Gegevens laden

Na het extraheren, schonen en transformeren van de gegevens zijn de gegevens eindelijk klaar om in het datawarehouse te worden geladen. We herhalen hier alleen maar dat een schema moet worden ingesteld voor het regelmatig bijwerken van het datawarehouse nadat voor de eerste keer gegevens zijn geladen, of het nu dagelijks, wekelijks, maandelijks of met een ander tijdsinterval is. Onthoud ook dat de datamarts die het datawarehouse als gegevensbron gebruiken, ook in het schema van regelmatige bijwerkingen moeten worden opgenomen.

14.5 Een datawarehouse gebruiken

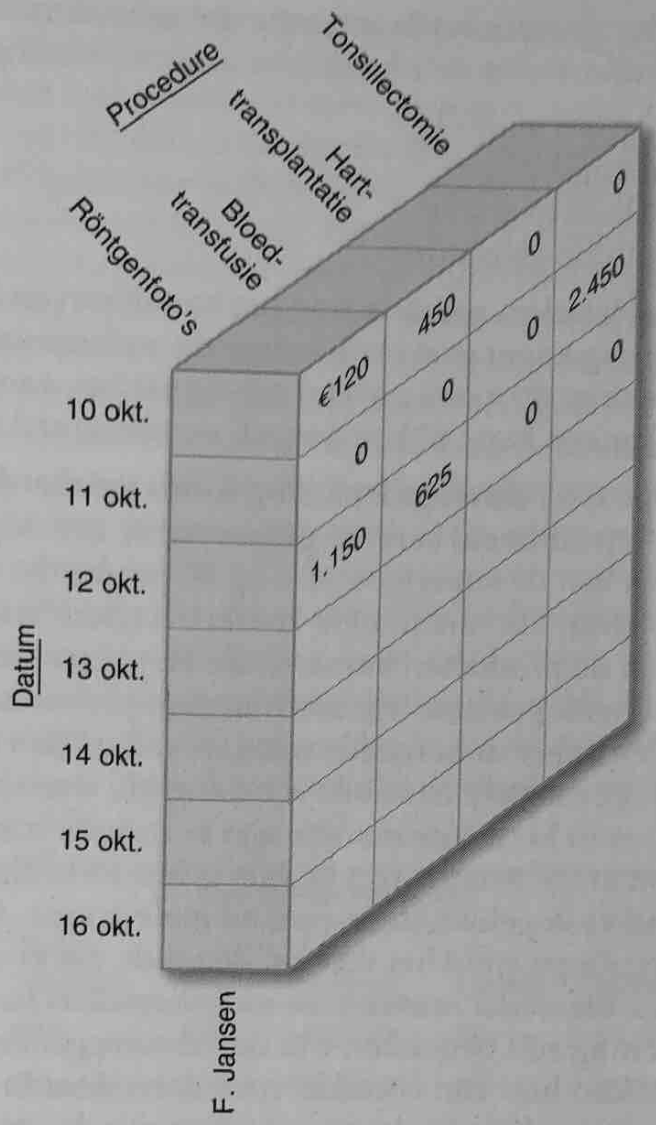
We hebben gezegd dat het doel van een datawarehouse is de besluitvorming van de leiding te ondersteunen. Dergelijke beslissingondersteuning en de hulpmiddelen daarvoor zijn op zichzelf belangrijke onderwerpen, maar niet iets waar we hier heel diep op ingaan. Het zou echter toch een beetje onbevredigend zijn om in een hoofdstuk over datawarehouses helemaal niets te zeggen over de manier waarop ze worden gebruikt. We bespreken daarom kort twee grote gebruiksgebieden van datawarehouses: **interactieve analytische verwerking** en **data-mining**.

14.5.1 Interactieve analytische verwerking

Interactieve analytische verwerking (*On-Line Analytic Processing, OLAP*) is een beslissingsondersteunende methodologie die is gebaseerd op het bekijken van gegevens in meerdere dimensies. We hebben dit onderwerp eerder in dit hoofdstuk in feite al zijdelings aangestipt toen we de twee-, drie- en vierdimensionale scenario's voor het vastleggen van patiënt- en factuurgegevens in een ziekenhuis bespraken. Er zijn tegenwoordig veel OLAP-systemen op de markt. Sommige hebben databasestructuren die speciaal zijn bedoeld voor multidimensionale OLAP-achtige gegevens. Andere, de zogenoemde relationele OLAP-systemen oftewel ROLAP-systemen, slaan multidimensionale gegevens in relationele databases op met behulp van een sterschema.

Hoe kunnen OLAP-gegevens worden gebruikt? De multidimensionale gegevens van de OLAP-omgeving zijn heel geschikt voor het opvragen van gegevens en voor trendanalyses over meerdere tijdsperioden, zoals we in het stuk over sterschema's hebben gezien. Daarnaast worden OLAP-gegevens ook vaak gebruikt voor andere zoekacties:

- **Drill-down:** Met 'drill-down' wordt bedoeld het teruggaan naar de database en het ophalen van gedetailleerdere gegevens dan eerder zijn opgehaald. Als u begint met geaggregeerde maandgegevens, kunt u teruggaan naar de database en naar de week- of daggegevens kijken, als het datawarehouse dit ondersteunt.
- **Slice:** Een 'slice' (plakje) van multidimensionale gegevens is een subset van de gegevens die zich concentreert op één waarde van een van de dimensies. Figuur 14.13 is een slice van de kubus van patiëntengegevens in figuur 14.4, waarin de waarde van één patiëntenattribuut is vastgezet (F. Jansen) en de gegevens in de andere dimensies worden weergegeven.
- **Pivot of rotatie:** Het draaien (*pivot*) of roteren van gegevens is weliswaar handig om de gegevens te visualiseren, maar het gaat hier vooral om het verwisselen van de gegevensdimensies, bijvoorbeeld om het verwisselen van de gegevens op de horizontale as en de gegevens op de verticale as in een tweedimensionale weergave.



Figuur 14.13: Een 'slice' van de gegevens in het patiëntvolg- en factureringssysteem van een ziekenhuis

14.5.2 Data-mining

Nu er enorme datawarehouses worden gebouwd en gegevens steeds meer worden beschouwd als een echt bedrijfsmiddel, is er een natuurlijke beweging gaande om steeds meer concurrentievoordeel uit de gegevens van een bedrijf te slepen. Dit geldt vooral voor het datawarehouse, dat tenslotte niet bedoeld is om de dagelijkse bedrijfsvoering te ondersteunen, maar er is om de leiding te helpen de concurrentiepositie van het bedrijf op alle mogelijke manieren te verbeteren. Datawarehouses worden zeker veel gebruikt in combinatie met de uiterst flexibele mogelijkheden voor het zoeken en ophalen van gegevens die OLAP-achtige tools en technieken bieden. Een ander gebruik van datawarehouses valt onder het kopje van de data-mining.

Met **data-mining** wordt bedoeld het zoeken naar verborgen kennis in de gegevens van het bedrijf die het bedrijf concurrentievoordeel kan opleveren. Dit gebeurt niet door mensen die handmatig de gegevens bestuderen, want ze zouden compleet overdonderd worden door de enorme hoeveelheid gegevens in het datawarehouse van het bedrijf. De data-mining wordt gedaan

door zeer geavanceerde software die gebruikmaakt van diverse geavanceerde statistische technieken en artificial-intelligence-technieken zoals:

- case-based learning;
- beslissingsbomen;
- neurale netwerken;
- genetische algoritmen.

Deze technieken vallen buiten het bestek van dit boek, dat immers over databasemanagement gaat en niet over de ondersteuning van de besluitvorming. Het is echter de moeite waard om vanuit het standpunt van een toepassing of gebruiker een korte blik te werpen op een aantal mogelijkheden.

Een type data-miningtoepassing wordt **market-basket-analyse** genoemd. Neem bijvoorbeeld eens de gegevens die een supermarkt verzamelt bij het scannen van de streepjescodes op de producten aan de kassa. Het bedrijf kan software de verzamelde 'market-baskets' laten bestuderen, die elk letterlijk de producten bevatten die een bepaalde klant in één keer in de winkel heeft gekocht. De software kan proberen vast te stellen of bepaalde artikelen vaker in hetzelfde mandje 'vallen' dan anders zou worden verwacht. Die laatste zinsnede is belangrijk, want bepaalde combinaties van artikelen in hetzelfde mandje zijn te voor de hand liggend of te algemeen om van enige waarde te zijn. Het is bijvoorbeeld niets bijzonders wanneer iemand vaak gelijktijdig eieren en melk koopt. Aan de andere doet in de data-miningwereld het verhaal de ronde dat er ooit een studie is verricht waaruit bleek dat mensen die wegwerpluiers kochten, ook vaak bier kochten (u mag zelf bedenken wat de achterliggende reden hiervoor is). Het bedrijf kon hier zijn voordeel mee doen door in zijn winkels in de buurt van de luiers wat bier te plaatsen, in de hoop dat de mensen die luiers kwamen kopen, ook een impulsaankoop zouden doen en wat bier zouden meenemen. Een andere benutting van market-basket-gegevens maakt deel uit van de opkomende marketingdiscipline die zich bezighoudt met het beheer van klantrelaties. Als een supermarkt via data-mining constateert dat een bepaalde klant die veel geld in de winkel uitgeeft, vaak een bepaald product koopt, kan het bedrijf de klant als beloning kortingsbonnen voor dat product aanbieden in de hoop dat de klant terug blijft komen.

Een ander type data-miningtoepassing kijkt naar patronen in de gegevens. Eerder hebben we gesuggereerd dat Lucky Rent-A-Car demografische gegevens over zijn klanten zou kunnen kopen om de gegevens die het in zijn eigen datawarehouse heeft, te verrijken. Bekijk nogmaals figuur 14.11 met de verrijkte dimensietabel KLANT (met toegevoegde attributen Leeftijd, Inkomen en Opleiding). Veronderstel, en dit is heel realistisch, dat Lucky een koppeling heeft gemaakt van de feitentabel VERHUUR met de dimensietabellen AUTO en KLANT, waarbij in het resultaat alleen de attributen zijn opgenomen die kunnen helpen bepalen wie de beste klanten zijn, bijvoorbeeld wie veel geld besteedt aan het huren van auto's in de 'luxe' klasse. Figuur 14.14 geeft de resulterende tabel weer, waarin de rijen voor het gemak aan de linkerkant zijn genummerd. De attributen Klasse en Naam fabrikant zijn afkomstig uit de tabel AUTO, het attribuut Kosten (de

inkomsten voor een bepaalde verhuurtransactie) uit de tabel VERHUUR en de attributen Klantnummer, Leeftijd, Inkomen en Opleiding uit de tabel KLANT. Er zouden weliswaar veel meer gegevens nodig zijn dan de hier getoonde gegevens om statistisch significante patronen te kunnen vinden, maar de voorbeeldgegevens in deze figuur geven u wel een globaal idee van hoe een patroon eruit kan zien. De rijen 2, 5, 8 en 11 hebben allemaal betrekking op verhuurtransacties van luxe auto's met hoge kosten (inkomsten voor het bedrijf). Als u in deze rijen de demografische gegevens van de klanten bekijkt, ziet u 'clusters' in leeftijd, inkomen en opleiding. Deze dure, luxe auto's zijn allemaal gehuurd door veertigers met een hoog inkomen en een hoge opleiding. Aan de andere kant hebben ook de rijen 10 en 14 betrekking op mensen die een hoog inkomen en een hoge opleiding hebben. Dit zijn echter geen veertigers en ze huurden ook geen luxe auto, en kregen dus evenmin een hoge rekening gepresenteerd. Wanneer Lucky voldoende van zulke gegevens heeft, zou het bedrijf mogelijk kunnen concluderen dat het meer kan verdienen door veel reclame voor zijn duurdere auto's te maken onder hoogopgeleide klanten die in de veertig zijn en een hoog inkomen hebben. Als de concurrenten van Lucky dit patroon nog niet hebben ontdekt, heeft Lucky concurrentievoordeel door gegevens uit zijn datawarehouse te delven.

AUTO/VERHUUR/KLANT

	Klasse	Naam fabrikant	Kosten	Klant-nummer	Leeftijd	Inkomen	Opleiding
1	Compact	Ford	320	884730	54	58.000	HBO
2	Luxe	Mercedes	850	528262	45	158.000	MBA
3	Full-size	Opel	489	109565	48	62.000	HBO
4	Subcompact	Toyota	159	532277	25	34.000	MBO
5	Luxe	Mercedes	675	155434	42	125.000	Gepromoveerd
6	Compact	Chrysler	360	965578	64	47.500	MBO
7	Mid-size	Nissan	429	688632	31	43.000	MBA
8	Luxe	Mercedes	925	342786	47	95.000	Universitair
9	Full-size	Opel	480	385633	51	72.000	HBO
10	Compact	Toyota	230	464367	64	200.000	Universitair
11	Luxe	Jaguar	1170	528262	45	158.000	MBA
12	Subcompact	Nissan	89	759930	29	28.000	HBO
13	Full-size	Ford	335	478432	57	53.500	HBO
14	Full-size	Chrysler	328	207867	29	162.000	Gepromoveerd

Figuur 14.14: Verrijkte gegevens van Lucky Rent-A-Car, geïntegreerd ten behoeve van data-mining

14.6 Een datawarehouse beheren

Eerder in dit boek hebben we het gehad over het beheer van de gegevens en databases van bedrijven door gegevensbeheerders en databasebeheerders. Het datawarehouse is een enorme database en moet dus serieus worden beheerd. Vanwege het unieke karakter van een datawarehouse is het beheer ervan ook iets waar zeer gespecialiseerd personeel voor nodig is. Er zijn zelfs mensen die de functie een eigen naam hebben gegeven: **datawarehousebeheerder**. Voor het beheren van een datawarehouse zijn drie soorten sterk overlappende expertise nodig:

- Kennis van het bedrijf:
  - kennis van de bedrijfsprocessen van het bedrijf, die ten grondslag ligt aan kennis van de transactiegegevens en databases van het bedrijf;
  - kennis van de zakelijke doelen van het bedrijf om te kunnen helpen bepalen welke gegevens in het datawarehouse moeten worden opgeslagen voor uiteindelijke OLAP- en data-miningdoeleinden.
- Kennis van de gegevens:
  - kennis van de transactiegegevens en databases van het bedrijf voor de selectie en integratie van gegevens in het datawarehouse;
  - kennis van de transactiegegevens en databases van het bedrijf om het schonen van gegevens en de transformatie van gegevens op te zetten en te begeleiden, voor zover nodig;
  - bekendheid met externe gegevensbronnen voor de acquisitie van verrijkingsgegevens.
- Technische expertise:
  - kennis van de ontwerpbeginselen voor het eerste ontwerp van datawarehouses;
  - kennis van OLAP- en data-miningtechnieken, zodat het ontwerp van het datawarehouse deze processen goed ondersteunt;
  - kennis van de transactiedatabases van het bedrijf om de regelmatig geplande toevoegingen van nieuwe gegevens aan het datawarehouse te begeleiden en te coördineren;
  - kennis van het werken met zeer grote databases in het algemeen (want het datawarehouse zal onvermijdelijk zeer groot zijn) met de unieke eisen die zij stellen op het gebied van de beveiliging, back-up en recovery, verdeling over meerdere schijfstations, enzovoort.

Het andere punt zijn metagegevens: het datawarehouse moet ook een data dictionary hebben. Het datawarehouse is een enorm omvangrijke gegevensbron voor het bedrijf en biedt het bedrijf allerlei mogelijkheden om concurrentievoordeel te behalen. Daarvoor moeten de werknemers van het bedrijf echter wel weten welke gegevens ze in het datawarehouse kunnen vinden, en wel om twee redenen: op de eerste plaats om te kunnen nadenken hoe ze de gegevens, via OLAP en data-mining, in het voordeel van het bedrijf kunnen aanwenden en op de tweede plaats om werkelijk toegang tot de gegevens te krijgen om ze met deze technieken te verwerken.

14.7 Uitdagingen van datawarehousing

Datawarehouses brengen zo hun eigen uitdagingen met zich mee. Veel bedrijven hebben zich onbesuisd op datawarehouses gestort en merken dat er veel meer bij komt kijken dan ze hadden gedacht. Vaak proberen ze het nog eens met een geleidelijkere aanpak en slagen dan uiteindelijk wel. Veel van de valkuilen van datawarehousing zijn in dit hoofdstuk al genoemd: de technische uitdagingen van het schonen van gegevens wanneer meer "verwilde" gegevens worden gevonden dan verwacht, problemen met de coördinatie van de regelmatige toevoegingen van nieuwe gegevens uit de transactiedatabases aan het datawarehouse en problemen met het beheer van een zeer grote database, wat een datawarehouse nu eenmaal is. Daarnaast is er nog de uitdaging dat de data dictionary moeten worden opgebouwd en onderhouden en dat ervoor moet worden gezorgd dat iedereen die het datawarehouse nodig heeft, weet welke gegevens in het datawarehouse te vinden zijn en toegang heeft tot deze gegevens.

Een grote uitdaging van geheel andere aard is dat moet worden geprobeerd te voldoen aan de wensen van de gebruikersgemeenschap. In beginsel is het idee dat een datawarehouse zo breed en algemeen wordt gebouwd, dat het in alle behoeften van de gebruikers voorziet. In de praktijk moeten echter keuzen worden gemaakt over het soort gegevens en de hoeveelheid gegevens die handig is om op een bepaald moment en op een bepaald punt in de ontwikkeling van het datawarehouse in het datawarehouse op te nemen. Helaas is het bijna onvermijdelijk dat bepaalde gebruikers in algemene zin niet tevreden zijn over de gegevens waarover ze kunnen beschikken en dat anderen willen dat het datawarehouse in zeker opzicht wordt aangepast, zodat het betere of andere resultaten voortbrengt. En dat is helemaal niet erg! Het betekent dat mensen in het bedrijf de enorme potentiële waarde van het datawarehouse begrijpen of oog voor deze waarde beginnen te krijgen en dat ze het graag zo snel mogelijk zo opgezet willen zien, dat zij het bedrijf optimaal kunnen helpen, ook als dat betekent dat de gegevens in het datawarehouse en het ontwerp van het datawarehouse voortdurend in beweging blijven.

Kernbegrippen

Beslissingondersteunend systeem (DSS)
Datamart (DM)
Data-mining
Datawarehouse
Datawarehousebeheerder
Dimensie
Drill-down
Enterprise-datawarehouse (EDW)
Geaggregeerde gegevens
Gegevens laden
Gegevens schonen
Gegevensextractie
Gegevenstransformatie
Gegevensverrijking
Geïntegreerd
Historische gegevens

Market-basket-analyse
Multidimensionale database
Niet-vluchtig
Onderwerpgeoriënteerd
On-Line Analytic Processing (OLAP)
Pivot of rotatie
Slice
Sneeuwvlokontwerp
Sterschema
Tijdsafhankelijk
Transactieverwerkend systeem (TPS)

Vragen

1. Wat is het verschil tussen transactieverwerkende systemen en beslissingondersteunende systemen?
2. Beslissingondersteunende toepassingen zijn er al vele jaren en maken doorgaans gebruik van bestanden die bij een bepaalde toepassing horen. Welke factoren hebben geleid tot de verschuiving van deze omgeving naar het datawarehouse?
3. Wat is een datawarehouse? Waar wordt een datawarehouse voor gebruikt?
4. Licht elk van de onderstaande uitspraken toe. De gegevens in een datawarehouse:
   a. zijn onderwerpgeoriënteerd;
   b. zijn geïntegreerd;
   c. zijn niet-vluchtig;
   d. hebben een tijdscomponent;
   e. moeten van hoge kwaliteit zijn;
   f. kunnen geaggregeerd zijn;
   g. zijn vaak gedenormalsieerd;
   h. zijn niet noodzakelijk helemaal actueel.
5. Wat is het verschil tussen een enterprise-datawarehouse en een datamart?
6. In welke omstandigheden zal een bedrijf datamarts bouwen op basis van een enterprise-datawarehouse? En in welke omstandigheden zal het een enterprise-datawarehouse bouwen op basis van datamarts?
7. Wat is een multidimensionale database?
8. Wat is een sterschema? Wat zijn feitentabellen? Wat zijn dimensietabellen?
9. Wat is een sneeuwvlokelement in een sterschema?
10. Wat zijn de vier stappen voor het bouwen van een datawarehouse, nadat dit is ontworpen?
11. Noem en beschrijf drie potentiële problemen die zich bij transactiegegevens kunnen voordoen waardoor de gegevens moeten worden geschoond voordat ze in een datawarehouse kunnen worden opgeslagen.
12. Noem en beschrijf drie soorten gegevenstransformaties die nodig kunnen zijn wanneer transactiegegevens worden geïntegreerd en gekopieerd naar een datawarehouse.
13. Wat is interactieve analytische verwerking (On-Line Analytic Processing, OLAP)? Wat heeft OLAP te maken met datawarehouses?
14. Wat wordt bedoeld met de onderstaande OLAP-begrippen?
   a. drill-down;
   b. slice;
   c. pivot of rotatie.
15. Wat is data-mining? Wat heeft data-mining van doen met datawarehouses?

16. Beschrijf de ideale achtergrond van een medewerker die het datawarehouse gaat beheren.
17. Beschrijf de uitdagingen waar een bedrijf voor komt te staan wanneer het een datawarehouse wil laten voldoen aan de wensen van de gebruikersgemeenschap.

Oefeningen

1. Het datawarehouse van Video Centers of Europe, Ltd.:
   a. Ontwerp een multidimensionale database met een sterschema voor een datawarehouse voor de bedrijfsomgeving van Video Centers of Europe, Ltd., zoals deze is beschreven in het diagram in oefening 2 in hoofdstuk 3. Het onderwerp zal 'verhuur' zijn, dat staat voor een bepaalde band of dvd die door een bepaalde klant is verhuurd. Houd de verhuurdatum en de betaalde prijs bij, zoals in oefening 2 in hoofdstuk 3 is aangegeven. Neem een sneeuwvlokelement op gebaseerd op de entiteiten acteur, film en band/dvd.
   b. Beschrijf drie OLAP-toepassingen van dit datawarehouse.
   c. Beschrijf een data-miningtoepassing van dit datawarehouse.
2. Het datawarehouse van Best Airlines, Inc.: In eerdere oefeningen in dit boek hebben we de onderstaande relationele database gezien, die Best Airlines onderhoudt om gegevens over zijn mecaniciens, hun deskundigheden en hun luchthavenlocaties bij te houden. De velden Mecaniciennummer, Luchthavennaam en Deskundigheidsnummer zijn alle drie uniek. Het veld Grootte staat voor de oppervlakte van de luchthaven in hectaren. Het veld Deskundigheidscategorie is een categorie deskundigheden, zoals een deskundigheid op het gebied van motoren, vleugels of banden. Kwalificatiejaar is het jaar waarin een mecanicien zich voor het eerst heeft gekwalificeerd in een bepaalde deskundigheid; Beoordeling is de beoordeling die de mecanicien voor de vaardigheid in kwestie heeft gekregen.

Tabel MECANICIEN				
Mecaniciennummer	Mecaniciennaam	Telefoon	Salaris	Luchthavennaam

Tabel LUCHTHAVEN				
Luchthavennaam	Plaats	Land	Grootte	Openingsjaar

Tabel DESKUNDIGHEID		
Deskundigheidsnummer	Deskundigheidscategorie	Deskundigheid

Tabel KWALIFICATIE			
Mecaniciennummer	Deskundigheidsnummer	Kwalificatiejaar	Beoordeling

We voegen nu de onderstaande tabellen aan de database toe die gegevens vastleggen over vliegtuigen en de mecaniciens die aan deze vliegtuigen hebben gewerkt. Een onderhoudsgebeurtenis is een specifieke onderhoudsactiviteit die aan een vliegtuig is uitgevoerd.