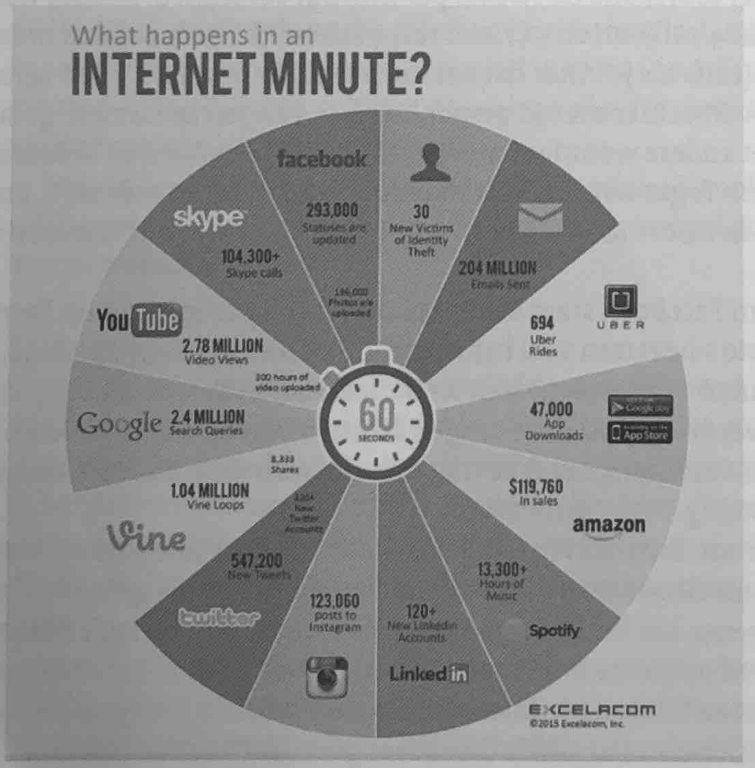
Hoofdstuk 7

# Big Data en Advanced Analytics

Het hele boek tot nu toe beschrijft de klassieke manier van Business Intelligence. In die klassieke manier worden (voornamelijk) eigen relationele databases ontsloten via datewarehouses en andere BI-tools. De bronnen die we besproken hebben zijn veelal CRM-systemen, ERP-systemen en andere transactie-georiënteerde systemen. Dat is tevens het soort systeem waar relationele database-platformen zoals SQL Server en Oracle excelleren. Het zijn ook de systemen waar we ons eind jaren tachtig/begin jaren negentig van de vorige eeuw voornamelijk mee bezig hielden. Maar slechts een fractie van de digitale gegevens die wereldwijd bestaan, zit in relationele databases. We gebruiken in klassieke BI dus meer data (en dus 'potentiële' informatie) niet dan wel. Met Big Data gaan we ook veel gegevens die niet in relationele databases zitten wel gebruiken. Je kan dan denken aan sensordata, logfiles, ongestructureerde teksten, foto's, gegevens in zogenaamde noSQL databases en ga zo maar door. Eigenlijk alle digitaal opgeslagen data bevat informatie. Met Big Data willen we die informatie ontsluiten.

## 7.1 Introductie Big Data

Big Data heeft niet rechtstreeks iets te maken met het internet, sociale media of met web 2.0. Tegelijkertijd is het geen toeval dat de opkomst van Big Data volgt op de opkomst van web 2.0. Kijk bijvoorbeeld eens naar figuur 7.1.




**Figuur 7.1** - *Hoeveelheid nieuwe data per minuut*

Figuur 7.1 is alweer een verouderd plaatje. De statistieken gaan over 2015. De getallen zullen ondertussen weer een stuk groter zijn. Let wel dat het hier gaat om aantal acties of hoeveelheid nieuw gegenereerde gegevens per minuut! Het gaat hier echter om het idee. Als je kijkt naar Amazon, zie je $119.760 in sales staan. Daar gaat het eigenlijk om een min of meer klassiek order entry-systeem, dus het registreren van transacties. Alleen gaat het hier door het internet wel om een 24/7 wereldwijd systeem. Dat levert op operationeel niveau wat uitdagingen op. En ook een datawarehouse zal qua grootte tegen serieuze uitdagingen aanlopen.

Voor figuur 7.1 zijn gegevens verzameld en in een plaatje samengebracht. De gegevens beschrijven het verleden. Maar Amazon heeft zo veel gegevens uit het verleden dat ze daarmee in staat zijn voorspellingen te doen over toekomstig koopgedrag van klanten. Ze hebben een zogenaamd recommendersysteem gemaakt, ofwel een systeem dat inschat waarin jij als klant geïnteresseerd bent. Dat resulteert in aanbevelingen op de site. Tegenwoordig heeft bijna elke webwinkel wel zo'n systeem. Als je ergens op zoekt, krijg je suggesties over andere artikelen die ook interessant voor je kunnen zijn. Zo n recommendersysteem maakt een geïnformeerde beslissing welke andere artikelen te tonen. En het nemen van beslissingen op basis van informatie, was dat nou net niet het doel van BI?

Het voorbeeld van een recommendersysteem laat zien dat we andere soorten vragen zijn gaan stellen. Een datawarehouse zoals dat tot nu toe in dit boek besproken is, kan goed vragen beantwoorden over de omzet van een bepaald artikel in het voorgaande jaar. Het is minder goed in staat om in realtime te voorspellen wat een nu ingelogde klant misschien wel gaat kopen.

Zoals gezegd is een webwinkel zoals Amazon nog redelijk te vergelijken met klassieke systemen. Het wordt al anders als we bijvoorbeeld gaan kijken naar Twitter en e-mail. Er worden heel veel mails en tweets per minuut verstuurd. In 2015 waren dat er volgens figuur 7.1 204 miljoen en 547.200 respectievelijk. In deze berichten zit heel veel informatie (zelfs als je vindt dat het meeste maar onzin is!). Een (groot) deel van deze informatie valt echter niet zo gemakkelijk te vangen in namen, getallen en datums. Het valt, met andere woorden, niet gemakkelijk te vangen in kolommen met datatypes in databases. Erger nog, het valt moeilijk te analyseren met SQL. En dus rijst de vraag: krijgen we de informatie die er in verborgen zit er wel uit? Kunnen we het wel gebruiken?

Bij de taartpunt van Facebook staat dat er 136.000 foto's per minuut op Facebook worden gezet. Ook foto's bevatten veel informatie. Staan er mensen op? Zo ja, hoeveel dan? En zijn het mannen of vrouwen? Van welke leeftijd? Wat is de sfeer op de foto? Gespannen, vrolijk, verdrietig? Al deze vragen kunnen van belang zijn. Maar met SQL en met klassieke datawarehouses zijn ze niet te beantwoorden. Daarom ontplooien steeds meer bedrijven Big Data-initiatieven.

In paragraaf 1.1.2 staat: Business Intelligence heeft als doel competitief voordeel te creëren en organisaties slimmer te kunnen laten werken. Anders gezegd is het doel van Business Intelligence om beslissingen te nemen, maar dan wel goed onderbouwde beslissingen gebaseerd op juiste informatie. Met dat voor ogen is het onbestaanbaar dat je de grootste hoeveelheid aan informatie die voor handen is negeert en alleen gegevens uit je operationele relationele databases gebruikt voor de informatievoorziening.

### 7.1.1 Beperkingen van klassieke datawarehouses

Zoals het voorgaande duidelijk maakt zijn er zinvolle vragen die een klassiek datawarehouse niet (goed) kan beantwoorden. Klassieke datawarehouses hebben een aantal tekortkomingen. Grofweg zijn dat:

- Er worden voornamelijk (alleen?) relationele bronnen ontsloten.
- Het is moeilijk realtime datawarehouses te maken.
- Datawarehouses zijn niet heel geschikt voor Advanced Analytics.

*Voornamelijk relationele bronnen*

In het vorige hoofdstuk, toen we het over ETL hadden, is gezegd dat het van belang is dat een ETL-tool veel verschillende soorten bronnen kan ontsluiten. Immers, niet al je applicaties zullen zijn gebaseerd op het RDBMS. Bovendien moet je misschien externe reference data inlezen. Dat kan in vele formaten aangeleverd worden.

Tegelijkertijd is SQL Server Integration Services (SSIS) genoemd als voorbeeld van een ETL-tool. SSIS is heel goed in het verwerken van gestructureerde gegevens. Het formaat van de gegevens die je krijgt aangeleverd is elke keer hetzelfde en vooraf bekend. Als echter de structuur van dag tot dag verschillend is, of alle informatie zit in één tekenreeks van 140 karakters zonder dat je weet wat er in die tekenreeks zit (referenties met @, hashtags, platte tekst), dan wordt het opeens heel lastig om die gegevens met SSIS te verwerken tot iets bruikbaars.

Het maakt SSIS eigenlijk niet uit waar de gegevens vandaan komen. Het kan vele bronnen benaderen. SSIS wil echter wel de structuur van de gegevens vooraf weten, zoals je dat hebt met relationele databases maar ook bij tekstbestanden waar goede documentatie beschrijft hoe dat tekstbestand is opgebouwd.

De hele datawarehouse-theorie komt uit de tijd dat we eigenlijk alleen met relationele databases werkten. En tabellen in relationele databases zijn de meest gestructureerde vorm van gegevens. Een tabel is vooraf gedefinieerd met kolommen en datatypes. Je gegevens voldoen daar altijd aan. De theorie is daarmee gebaseerd op het verwerken van dit soort gegevens.

Met andere woorden: vaak worden in klassieke BI-oplossingen alleen maar de eigen relationele databases ontsloten. We negeren de mogelijkheden die andere gegevens kunnen bieden.

*Realtime datawarehousing*

In veel BI-oplossingen die in het verleden zijn gebouwd is het ETL-proces een nachtelijk batchproces. Dat betekent dat we overdag nieuwe en gewijzigde gegevens krijgen in de operationele databases en dat we die wijzigingen pas in de nacht verwerken en in het datawarehouse opnemen. Eerder in het boek is gezegd dat deze latency in de informatie voor veel beslissingen geen probleem is. Veel met name managementbeslissingen kunnen prima gemaakt worden op basis van de stand van zaken tot en met gisteren.

In een magazijn van bijvoorbeeld een supermarkt moet echter in de loop van de middag besloten worden of er nog een vrachtauto met brood de weg op gestuurd wordt om winkels te bevoorraden. Om dat besluit te nemen moet je nu weten hoeveel winkels bijna of helemaal geen voorraad meer hebben. Je moet nu weten hoeveel het kost

een vrachtwagen te laten rijden, hoeveel extra broden toch niet verkocht gaan worden en wat dat kost, en hoeveel extra omzet je haalt door meer broden te kunnen verkopen.

Voor bovengenoemd besluit heb je niets aan voorraadinformatie van gisteren. Je moet die informatie in realtime hebben. Het zit er echter dik in dat de informatie per winkel in een aparte database zit. De gegevens moeten eerst in een centrale (reporting)database gestopt worden en dat kost tijd.

In de loop van de jaren zijn er natuurlijk allemaal oplossingen bedacht om dit soort problemen op te lossen. Vaak introduceren die extra complexiteit en extra kosten.

*Advanced Analytics*

De derde tekortkoming die genoemd is voor datawarehouses is dat ze niet altijd even geschikt zijn voor Advanced Analytics. Paragraaf 7.4 gaat daar uitgebreider op in. Voor nu is het goed om ons te realiseren dat de term Advanced Analytics impliceert dat er ook zoiets is als Basic Analytics. Basic Analytics wordt prima ondersteund door klassieke datawarehouses. Advanced analytics een stuk minder. Zoals gezegd zal je later lezen hoe dat precies zit.

## 7.2 Definitie van Big Data

Techniek mag nooit een doel op zich worden, ook niet als het 'hot' is. Dat geldt uiteraard ook voor Big Data. De wereld is veranderd sinds de introductie van datawarehousing. We hebben nieuwe soorten digitale gegevens gekregen, we hebben ontzettend veel meer digitale gegevens, en we willen andere soorten vragen stellen dan voorheen. Als één of meer van deze punten een probleem wordt, moet je innoveren ten opzichte van je klassieke BI-oplossing. Je hebt te maken met Big Data.

> Big Data betekent dat het soort gegevens dat je hebt in combinatie met wat je er mee wilt doen, je dwingt te innoveren.

Heel flauw gezegd betekent dit ook dat als je grootste gegevensbestand een Excelsheet is, en je in de toekomst meer dan een miljoen rijen wilt gaan opslaan, je misschien wel moet gaan werken met MS Access of zelfs SQL Server.

Uiteraard is switchen van Excel naar Access geen Big Data-project. Het gaat echter om het idee. Zoals gezegd hebben we nieuwe soorten gegevens gekregen, hebben we meer gegevens gekregen, en stellen we andere soorten vragen. We hebben ook nieuwe software gekregen en ook de mogelijkheden van de hardware zijn gegroeid. Big Data is een verzamelnaam voor die nieuwe soort gegevens, Advanced Analytics is het stellen van die nieuwe vragen.

De nieuwe soort gegevens heeft drie (hoofd)kenmerken. Deze vormen samen de definitie van Big Data. Big Data wordt vaak gedefinieerd als de 3 V's (*www.gartner.com/it-glossary/big-data*).

**Big Data** wordt gedefinieerd door wat vaak de 3 V's wordt genoemd:
- Volume
- Variety
- Velocity

In de volgende paragrafen worden deze drie kenmerken verder besproken.

### 7.2.1 Volume

In mijn ogen staat het verkeerde kenmerk bovenaan en lijkt het vaak alsof het verkeerde kenmerk ook de naamgever is. Big in Big Data lijkt sterk te suggereren dat we te maken hebben met heel veel data. Het suggereert dat het volume van de gegevens heel groot is. Dit boek maakt zich daar ook schuldig aan door dit hoofdstuk te beginnen met figuur 7.1, dat ook de nadruk legt op de hoeveelheid gegevens die per minuut op het internet ontstaat.

Volume is niet het typerende kenmerk van Big Data, maar is zeker één van de kenmerken. De meeste relationele databases draaien op één server. Als die server het volume niet meer aankan, moet je een grotere server kopen. Dat noemen we scale-up. Maar wat als je al de grootste server hebt die er bestaat?

**Scale-up** is het inzetten van een grotere server.

Nog niet zo heel lang geleden vonden we een database van enkele honderden gigabyte groot. Nog altijd zijn de meeste databases kleiner dan dat. Tegelijkertijd hebben we het tegenwoordig regelmatig over petabyte (PB) of zelfs exabyte (EB). Een petabyte is duizend terabyte, is een miljoen gigabyte. Een exabyte is duizend petabyte. Gelukkig is ook de hardware een stuk krachtiger en betaalbaarder geworden. Toch loop je met scale-up onvermijdelijk een keer tegen de limiet aan. Voor SQL Server 2016 ligt die limiet bij enkele tientallen terabytes.

In plaats van een grotere server kopen kun je ook meer servers inzetten en het werk verdelen over die servers. Je maakt dan een zogenaamd cluster van servers. Dan doe je niet een scale-up maar een scale-out. Scale-out is in theorie oneindig schaalbaar. Je kan er altijd weer meer servers bijplaatsen.

**Scale-out** is het verdelen van de workload over een cluster van meerdere servers.

Microsoft verkoopt Analytic Platform Service (APS). Dit is een appliance, wat zoveel betekent als hardware en software ineen om een optimale service te garanderen. In dit geval is het eigenlijk SQL Server op een cluster van servers, compute-nodes genaamd. Het is dus een scale-outvariant van SQL Server. Met APS kan je een database maken van enkele petabytes. Andere leveranciers hebben vergelijkbare producten. Je kan dan bijvoorbeeld denken aan Exadata van Oracle, Netezza van IBM en Teradata.

Tot volumes van petabytes aan toe kunnen we dus oplossingen bouwen met relationele databases. Daarvoor is de theorie van de voorgaande hoofdstukken dus gewoon van toepassing. Uiteraard verg je dan het uiterste van je hardware en software, wat wel kosten met zich meebrengt. Bij nog grotere volumes kom je met het verwerken van je gegevens in de problemen. Wellicht dient een ander probleem zich echter eerst aan: een relationele database slaat gegevens op in tabellen en gaat dus uit van heel gestructureerde gegevens. Dat brengt ons op de tweede V: variety.

### 7.2.2 Variety

In het kader van variety kunnen we gegevens onderverdelen in drie soorten. Dat zijn:
- gestructureerde gegevens (Structured Data);
- semi-gestructureerde gegevens (Semi-structured Data);
- ongestructureerde gegevens (Unstructured Data).

*Gestructureerde gegevens*
Bij gestructureerde gegevens is er een schema, een datamodel, bekend. Met het schema wordt de metadata bedoeld: de beschrijving van alle kolommen, de datatypes van de kolommen en het domein (de mogelijke waarden) van de kolommen. Vaak is er sprake van een sterke koppeling tussen de gegevens zelf en de metadata. Een tabel in een database bevat de kolomdefinities, de metadata, en de gegevens zelf.

Er wordt ook vaak gesproken over schema-on-write. Voordat je een record kan wegschrijven in een database, moet er al een tabel zijn. De metadata is er dus eerder dan de gewone data.

Met **schema-on-write** bedoelen we dat de metadata al moet bestaan voordat de gewone gegevens opgeslagen kunnen worden.

---

Relationele databases zijn heel erg goed in dit soort gegevens op te slaan en te verwerken. Veel transactionele systemen, zoals financiële systemen, leveren voornamelijk dit soort sterk gestructureerde gegevens op. Relationele databases zijn daarmee voorlopig nog niet weg te denken uit de BI-wereld.

*Semi-gestructureerde gegevens*
Bij semi-gestructureerde gegevens is er nog wel sprake van enige metadata maar niet meer zo in ijzer gegoten als bij gestructureerde gegevens. Je kunt bijvoorbeeld denken aan gegevens in de vorm van XML of JSON. Waarschijnlijk is een beschrijving van de documentstructuur, de metadata, wel ergens beschikbaar. Maar dat is al niet noodzakelijk. Bovendien zit er veel meer vrijheid in deze structuur dan dat er vrijheid zit in een tabel.

Je zou ook kunnen denken aan bijvoorbeeld sensordata. Stel: je hebt overal in het land thermometers hangen en je verzamelt alle temperatuurmetingen. Op het eerste gezicht kan dat heel gestructureerd zijn. Je moet elke keer de locatie, de tijd en de temperatuur weten. Alleen zal vaak blijken dat je verschillende soorten thermometers hebt. Sommigen geven hun locatie door als een tekststring, andere met GPS-locaties

en weer andere met noorderbreedte en westerlengte. Op dezelfde manier geven sommigen de tijd weer in UTC, anderen geven de lokale tijd, soms tot op de seconde nauwkeurig, soms niet. Met andere woorden: het kan elke keer anders zijn. En in de toekomst gaan er nieuwe thermometers komen die de informatie weer op een andere manier doorgeven. Onze BI-oplossing moet de flexibiliteit hebben al deze varianten te kunnen verwerken, ook die varianten die wij nog niet kennen.

Zaken als e-mails, tweets en Facebookposts zijn ook semi-gestructureerd. Je weet altijd wel iets als afzender en tijdstip. Je weet dat er een bericht is. Maar het bericht zelf is gewoon tekst en dat kan van alles zijn. De opsteller heeft volledige vrijheid, dat is eigenlijk alles wat je weet.

Vaak vallen logbestanden ook onder de semi-gestructureerde gegevens. Het zijn grote bestanden met meldingen. Denk bijvoorbeeld aan de logbestanden van applicaties met allemaal meldingen en foutmeldingen ten aanzien van de applicatie. Vaak is er wel structuur met iets als een timestamp, errorcode en beschrijving, maar dat wordt niet afgedwongen in het logbestand zelf. We gebruiken die informatie pas als we de gegevens gaan verwerken. We noemen dat soms wel schema-on-read.

Met **schema-on-read** bedoelen we dat we de metadata die gegevens beschrijft pas gebruiken bij het verwerken van de gegevens, niet bij het schrijven (registreren) van die gegevens.

*Ongestructureerde gegevens*

Ten slotte heb je de ongestructureerde gegevens. Helemaal ongestructureerd is het nooit. Als je een bestandsformaat weet, heb je al kennis over het soort informatie.

Bij ongestructureerde data kan je denken aan bijvoorbeeld foto's. Als je een foto hebt in jpg-formaat dan weet een grafische expert wellicht vrij veel over pixels, kleur, helderheid en andere zaken. Voor de meesten van ons is de inhoud nietszeggend tenzij je het bestand opent in een foto-app.

Zoals eerder al genoemd kan een foto heel veel informatie bevatten. Als je bijvoorbeeld een foto maakt van een demonstratie kan je zien hoeveel mensen er zijn en wat voor soort mensen (leeftijd, geslacht). Als de gezichten herkenbaar zijn kan je wellicht achterhalen wie er op de vorige demonstratie ook waren. Ook zou je aan de gezichtsuitdrukking de stemming kunnen afleiden en zo in de gaten houden of de stemming aan het omslaan is. In stadions zijn dit soort toepassingen allang in gebruik en ook in het openbare leven komt dit steeds meer voor.

Van de totale hoeveelheid digitale gegevens die er wereldwijd bestaat, is maar een klein deel gestructureerd. Een groot deel is dus on- of semi-gestructureerd. Big Data-oplossingen zijn in staat deze gegevens om te zetten in zinvolle informatie. Informatie waarop wij beslissingen kunnen nemen. Dus worden onze BI-oplossingen beter met Big Data-implementaties. Big Data is daarmee aanvullend op klassieke BI, niet ter vervanging van.

Big Data is aanvullend op klassieke BI. Het is geen vervanging van klassieke BI.

### 7.2.3 Velocity

Het derde kenmerk van Big Data is velocity, ofwel snelheid. Dit kan twee dingen betekenen: de snelheid waarmee gegevens ontstaan of de snelheid waarmee we de gegevens moeten verwerken tot bruikbare informatie. Hier komt dus het al dan niet realtime zijn van databases om de hoek kijken.

Met streamingdata-applicaties kunnen grote hoeveelheden nieuwe data verwerkt en/of opgeslagen worden. Je moet dan bijvoorbeeld denken aan IoT-(Internet of Things)oplossingen waarbij veel nieuwe data gegenereerd wordt en waar in sommige situaties (bijna) meteen op die nieuwe data gereageerd moet worden.

### 7.2.4 Andere kenmerken

Sommige mensen nemen niet de 3 V's van Big Data als definitie maar komen met 4 of met 5 V's. De kenmerken die er dan bijkomen zijn:

- Veracity
- Value

*Veracity*

Mogelijke vertalingen voor veracity zijn waarheid, echtheid en geloofwaardigheid. In Big Data zegt het iets over de kwaliteit en betrouwbaarheid en over de hoeveelheid ruis in de gegevens. Kwaliteit en betrouwbaarheid spelen met name een rol bij gegevens die je extern krijgt. In dit boek heb ik bijvoorbeeld enkele definities overgenomen van Wikipedia. Maar hoe betrouwbaar is Wikipedia en daarmee de overgenomen definities? En als de input niet betrouwbaar is, wat zegt dat dan over de resultaten van de analyses die je uitvoert op die input?

Met ruis bedoelen we data (bytes) die niet tot informatie leidt. Een tabel in een database heeft bijna helemaal geen ruis. Elke byte bevat informatie. Een foto van 150 KB waaruit je alleen herleidt dat er drie mensen op staan die jonger dan tien jaar zijn, heeft heel veel ruis. Er zijn meer bytes die geen informatie bevatten dan bytes die dat wel doen. De signal-to-noise ratio is heel laag. Wegen bij een lage signal-to-noiseratio de kosten voor opslag en verwerking nog wel op tegen de meerwaarde die de informatie biedt?

De **signal-to-noiseratio** is de verhouding tussen informatie en ruis in data.

Enkele jaren geleden wogen de kosten van het analyseren van foto's niet op tegen de opbrengst. Met de toegenomen kracht van hardware en software (en met de introductie van de cloud met zijn bijna oneindige resources) is dat nu vaak niet meer waar. De grens schuift op.

*Value*

Met value wordt de meerwaarde van gegevens bedoeld, de bruikbaarheid. Vaak worden in artikelen en boeken over Big Data social media zoals Twitter gebruikt als voorbeeld. Maar hoe bruikbaar is Twitter eigenlijk? Het antwoord hangt natuurlijk volledig af

van wat je wilt. Welke vraag moet je beantwoorden? De waarde van Twitter is een stuk groter als je moet weten wat de publieke opinie over een grote Hollywoodfilm is dan wanneer je wilt weten of een hotel dat je wilt boeken goed is.
De waarde wordt naast de te beantwoorden vraag bepaald door vragen als:

- Is de data volledig?
- Wat is de veracity?

### 7.2.5 Tot slot

Business Intelligence is langzaam maar zeker aan het verschuiven van een Decision Support System (DSS) dat gebruikt wordt voor hoger management naar een operationeel systeem dat de dagelijkse besluitvorming ondersteunt. Daarmee ondersteunt het direct de primaire processen en geeft het bedrijven de kans beter te functioneren.

Door die verschuiving wordt het noodzakelijk een ander soort vragen te beantwoorden. Klassieke systemen beantwoorden vragen als: wat is de omzet per product per land en onderkennen we een trend in deze omzet? Nieuwe vragen zijn meer vragen als: hoe kan ik mijn vrachtwagens efficiënter inzetten, rekening houdend met het weer en het verkeer? Hoeveel grondstoffen moet ik nu inkopen om volgende maand precies aan de vraag van mijn klanten te kunnen voldoen? Die laatste vraag slaat de brug naar de volgende paragraaf: Advanced Analytics. Big Data kan daar een rol bij spelen, maar dat is niet noodzakelijk.

Voor deze nieuwe soort vragen hebben we andere soorten gegevens nodig. Bovendien hebben we andere computertalen nodig om de benodigde analyses uit te voeren. We moeten, met andere woorden, innoveren ten opzichte van klassieke BI-oplossingen. Je bent beland in de wereld van de Big Data.

Andersom geldt hetzelfde. Omdat we in staat zijn een andere soort gegevens te verwerken tot bruikbare informatie, kunnen we andere vragen gaan stellen. Internet of Things heeft geleid tot veel nieuwe gegevens. We hebben steeds meer sensordata. Logbestanden die vroeger een te slechte signal-to-noiseratio hadden, kunnen nu wel zinvol verwerkt worden. Langzaam leren we deze nieuwe, of tot nu toe niet benutte, bronnen zinvol te gebruiken.

In paragraaf 7.4 zullen we ingaan op Big Data-tools. Maar eerst zullen we ons focussen op de nieuwe soort vragen die we willen stellen. Dat is het terrein van de Advanced Analytics.

## 7.3 Advanced Analytics

In paragraaf 7.1 is Advanced Analytics al genoemd als iets waar klassieke datawarehouses bij tekortschieten. In deze paragraaf zullen we dat zoals beloofd nader toelichten. Tevens zullen we bekijken wat Advanced Analytics nu precies inhoudt.

### 7.3.1 Inleiding Data Analytics

Voordat we onderscheid maken tussen Basic en Advanced Analytics, kijken we naar wat Analytics of preciezer Data Analytics exact is. Data Analytics is het analyseren van

gegevensverzamelingen om besluitvorming te ondersteunen en theorieën te testen. Deze definitie lijkt erg op de definitie van Business Intelligence.

**Data Analytics** is het analyseren van gegevensverzamelingen om besluitvorming te ondersteunen en theorieën te testen

---

Misschien trapt het boek een beetje in de valkuil die enkele keren werden benoemd: de hoofdstukken 3 tot en met 6 richten zich erg op oplossingen. Op technieken. Het draait echter om het nemen van besluiten. Daarmee draait het om Data Analytics. In een datawarehouse worden interessante gegevens verzameld. Het gaat er om wat je met die gegevens doet. Het werken met die gegevens is het veld van de Analytics. De hoofdstukken 3 tot en met 6 zijn natuurlijk niet voor niets geschreven. De ervaring leert dat door het opzetten van datawarehouses en daaraan verwante technieken het proces van Data Analytics het best wordt gefaciliteerd.

Bij Analytics hoort ook het communiceren van de ontdekte patronen en van het verkregen inzicht. Over de communicatie van informatie volgt in hoofdstuk 9 nog meer.

Analytics is daarmee een methode, een werkwijze, waar data-analyse een onderdeel van is. Hierin zie je weer terug dat Business Intelligence meer is dan een datawarehouse. Het is een werkwijze die een onderdeel van de bedrijfscultuur en van de organisatie moet zijn.

**Analytics** is een werkwijze die een onderdeel moet zijn van de bedrijfscultuur.

---

Een datawarehouse, samen met technieken en tools om analyses uit te voeren, al dan op Big Data, is niet genoeg. Als je terugdenkt aan de Business Intelligence Maturity Matrix, hoort wat mensen doen met de geboden informatie bij de kenmerken van een volwassen organisatie. Het proactief toepassen van informatie en aansturing door de CIO worden expliciet genoemd. Als dat er is, kun je spreken van Analytics.

### 7.3.2 Basic Analytics

Klassieke datawarehouses zijn zoals gezegd een goede ondersteuning voor Basic Analytics. Wat precies onder Basic en Advanced Analytics wordt verstaan, verschilt per situatie. In dit boek definiëren we Basic Analytics als bestaand uit:

- Descriptive (Beschrijvende) Analytics;
- Diagnostic (Diagnostische) Analytics.

*Descriptive Analytics*

Descriptive, ofwel beschrijvende, Analytics doet eigenlijk precies wat de naam suggereert. Het beschrijft een situatie of een proces. We doen dat meestal door ruwe gegevens te aggregeren. De som van alle orders beschrijft de gehaalde omzet. We tellen hoeveel verschillende klanten we hebben gehad in een periode. We berekenen de gemiddelde marge en tonen de gemaakte winst.

De grootste beperking is dat we op deze manier altijd het verleden beschrijven. Descriptive Analytics is terugkijken in het verleden. Daarnaast is het vrij statisch. Een lijstje van getallen dat een proces beschrijft.

Descriptive Analytics is over het algemeen kwantitatief. Met eenvoudige statistische berekeningen (analyses) zoals gemiddeldes en sommaties beschrijven we met getallen wat er is gebeurd. Getallen zijn objectief en gemakkelijk vergelijkbaar.

Een dimensioneel gemodelleerde datamart zet gegevens klaar in een ideaal formaat voor Descriptive Analytics. De complexiteit wordt erg laag. Met eenvoudige rechttoe rechtaan query's kunnen de getallen berekend worden. Met elke rapportagetool kunnen de resultaten gecommuniceerd worden met alle betrokkenen.

*Diagnostic Analytics*

Diagnostic Analytics probeert een stap verder te zetten dan Descriptive Analytics. Het probeert de vraag 'Waarom is iets gebeurd?' te beantwoorden. We zijn dus niet tevreden met een getal dat de omzet laat zien of met hoeveel de omzet is gegroeid en gedaald. We willen weten waarom we zoveel groei hebben laten zien.

Voor een deel komt hier misschien de ervaring van een persoon bij kijken. Maar die persoon zal ook vaak een verdere analyse op de gegevens willen doen. Hij zal zaken als drill-down en drill-through willen doen en verder willen kijken naar individuele orders. Hij wil bekijken wat voor soort klanten die orders hebben besteld en of er een verband bestaat met het weer. Was het een goede of een slechte zomer? Voor een ijsverkoper kan dat van wezenlijk belang zijn.

Dus waar Descriptive Analytics bijvoorbeeld laat zien dat we vorig jaar in juli 10% meer omzet hebben gedraaid dan dit jaar, zegt Diagnostic Analytics dat dat komt omdat we vorig jaar een warmere zomer hadden dan normaal. Dat levert iets meer meerwaarde op maar is ook wat complexer.

### 7.3.3 Advanced Analytics

De nieuwe soort vragen waar het in de vorige paragraaf over ging, bevinden zich in het gebied van de Advanced Analytics. Advanced Analytics is onder te verdelen in:

- Predictive (voorspellende) Analytics
- Prescriptive (voorschrijvende) Analytics

*Predictive Analytics*

Denkend aan de ijsverkoper van de vorige paragraaf is het eigenlijk helemaal niet zo interessant om te weten hoeveel omzet hij gisteren heeft gehaald. Veel interessanter is het om te weten hoeveel omzet hij morgen gaat halen. Of nog verder in de toekomst. Met die kennis kan het bijvoorbeeld een stuk makkelijker worden om bij een bank een lening te krijgen om te investeren in een nieuwe ijsmachine. We gaan dus nu proberen de toekomst te voorspellen.

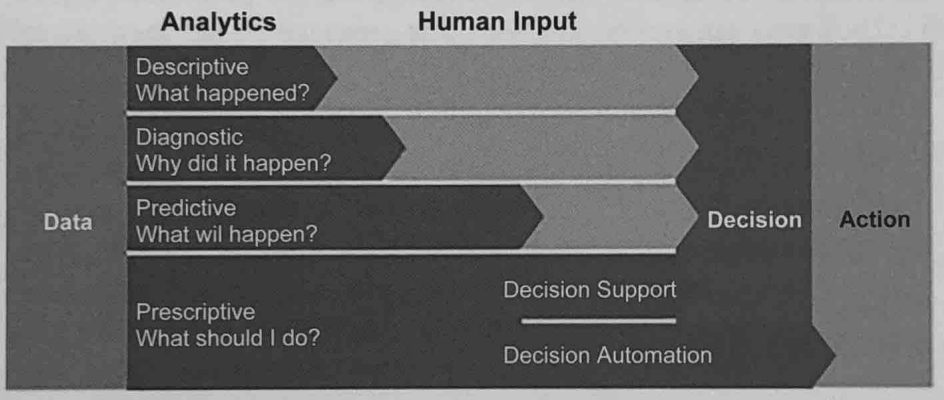
Enige nuance is hier natuurlijk wel op zijn plaats. De toekomst voorspellen bestaat niet. Het weerbericht is ook een weersverwachting, niet een weersvoorspelling. Maar met wat complexere statistische modellen, kunnen we berekenen met welke waarschijnlijkheid iets zou kunnen gaan gebeuren.

Met Predictive Analytics komen we uit bij datamining en machine learning. Om deze technieken goed toe te passen is extra, gespecialiseerde, kennis nodig. Data scientists hebben die expertise. Ze hebben gespecialiseerde tools en programmeertalen en vooral goede gegevensverzamelingen nodig om hun werk goed te doen. Klassieke BI-oplossingen voldoen vaak niet aan de benodigdheden voor data scientists.

*Prescriptive Analytics*

Als we nog eens goed nadenken over de ijsverkoper dan is het nu al weten wat morgen de omzet gaat worden nog altijd niet echt interessant. We leven immers pas nu. Wat moeten we nu doen? We moeten nu twee besluiten nemen: hoeveel ingrediënten gaan we inkopen en moeten we het uitzendbureau bellen om extra mensen voor achter de balie in te huren? Uiteraard volgen de antwoorden uit de voorspelling hoeveel ijs je gaat verkopen of potentieel zou kunnen verkopen. Je moet wel genoeg ijs hebben om te verkopen en genoeg mensen hebben om de klanten te bedienen.

Hiermee zijn we terug bij zowel de definitie van BI als bij die van Analytics: het gaat om het nemen van beslissingen. Figuur 7.2 laat dat nog eens zien.




**Figuur 7.2** *Analytics (Source Gartner)*

Figuur 7.2 laat zien dat het draait om beslissingen en de acties die daar uit volgen. Belangrijk hier is de human input. Analytics communiceert de bevindingen van de data-analyse. Dat moet leiden tot het nemen van beslissingen. Maar bij Descriptive Analytics zit er nog een aardig gat tussen een rapport en het nemen van een beslissing. Bij Prescriptive Analytics is dat gat helemaal weg. Als je in staat bent accuraat te voorspellen hoeveel ingrediënten je nodig hebt om voor morgen ijs te maken, kun je geautomatiseerd een bestelling naar de groothandel sturen!

Het voordeel van minder mensenwerk is dat er minder fouten gemaakt zullen worden en dat beslissingen sneller en accurater genomen kunnen worden.

### 7.3.4 Top-down versus bottom-up

Er is al enkele keren gezegd dat Advanced Analytics minder goed ondersteund wordt door klassieke BI en datawarehouses dan wat we in dit boek Basic Analytics noemen. Klassieke BI gebruikt een top-downbenadering. Voor de Predictive en Prescriptive Analytics heb je een bottom-upaanpak nodig. In figuur 7.3 wordt dit getoond.

*Top-down*

In een top-downbenadering ga je uit van een bestaande theorie. Vertaald naar Business Intelligence betekent dit dat je uitgaat van je kennis van het proces waar je aan werkt. Denk eens terug aan dimensioneel modelleren uit hoofdstuk 4. Je neemt een bestaand proces als uitgangspunt en dat modelleer je. In dat model stop je als het ware je kennis van het systeem.

Vervolgens maak je een hypothese over iets wat je waarneemt of van iets wat je wilt onderzoeken. De ijsverkoper van eerder neemt bijvoorbeeld waar dat hij 10% meer omzet heeft gehaald in juli dan vorig jaar. Zijn aanname, hypothese, is dat het warme weer daar de oorzaak van is. Hij bedenkt dus vooraf eerst een mogelijke verklaring.

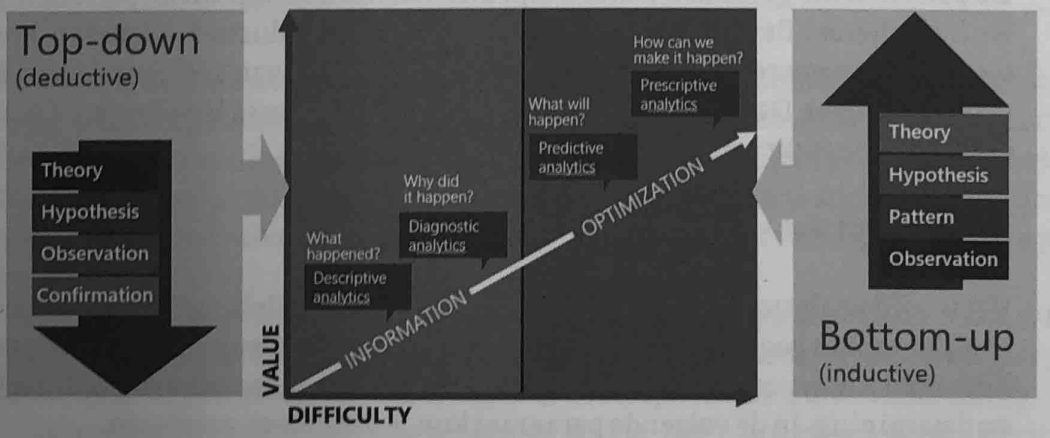
De hypothese moet in een volgende stap gecontroleerd worden. Misschien is het waar, misschien moeten we verder analyseren omdat er een andere oorzaak aan het waargenomen feit ten grondslag ligt. We controleren de hypothese door een rapport te maken (gebaseerd op het stermodel) dat het verband aantoont tussen omzet en temperatuur.

Het gemaakte rapport bevestigt de hypothese: de omzetstijging is te verklaren door de hogere temperatuur. De zojuist gedane analyse noemen we wel confirmatory analyse omdat we proberen een vooraf geopperd idee te bevestigen. Als de hypothese door de analyse wordt ontkracht, herhaalt het hele proces zich met een nieuwe hypothese.

**Confirmatory analyse** gebruikt een top-downbenadering om een vooraf gestelde hypothese te bevestigen.

---

Top-down gaat uit van kennis vooraf. De analyse kan gedaan worden op basis van het datawarehouse of op basis van een semantisch model dat gebaseerd is op het datawarehouse omdat er met voorkennis al rekening is gehouden met de mogelijkheid dat dit soort analyses uitgevoerd gaan worden.




**Figuur 7.3** *Top-down versus bottom-up*

*Bottom-up*

De top-downbenadering ondersteunt Descriptive en Diagnostic Analytics, maar schiet tekort voor Predictive Analytics. Je zou kunnen denken dat als je het weerbericht opvraagt en de te verwachten temperatuur bekijkt, je nu kunt voorspellen hoeveel ijs je morgen gaat verkopen. Hoewel dat niet raar gedacht is, blijkt zo'n benadering in de praktijk te simplistisch. Je voorspelling zal nauwelijks beter zijn dan gewoon gokken.

Voor Predictive Analytics draaien we de zaken om. Als uitgangspunt nemen we data, in figuur 7.3 observations genoemd. Het liefst beginnen we met ruwe, nog niet bewerkte, data. In bewerkte gegevens zijn misschien al (foutieve) aannames geïntroduceerd of zijn mogelijk relevante gegevens verwijderd. De dimensionele datamart is dus eigenlijk niet geschikt omdat tijdens de ETL en de cleansing allemaal bewerkingen zijn gedaan.

De ruwe gegevens worden geanalyseerd en tot een voor deze toepassing bruikbare verzameling omgevormd. Dit is een moeilijke maar zeer belangrijke stap. De gegevens waarop je voorspellingen baseert, bepalen grotendeels de betrouwbaarheid van de voorspelling die er uit komt. Je leest daar meer over in de paragraaf over machine learning.

Vervolgens analyseer je de gegevens, al dan niet met machine learning algoritmes om te proberen patronen in je data te ontdekken. Er zijn verschillende algoritmes die je kan gebruiken en welke je kiest en hoe je dat algoritme configureert heeft ook weer invloed op de betrouwbaarheid van de voorspelling. We noemen deze manier van analyseren exploratory analyse, omdat je als het ware op ontdekkingstocht gaat in je gegevensverzameling.

**Exploratory analyse** is een bottom-upbenadering waarbij je probeert zonder beïnvloeding vooraf patronen in datasets te vinden.

De patronen die gevonden worden zijn uiteindelijk leidend. Uit de patronen kunnen we hypotheses afleiden. We noemen dat inductie. Bij inductief redeneren, komt men tot een algemene regel, generalisatie geheten, op grond van een aantal specifieke waarnemingen. Daarmee heb je dan uiteindelijk het proces beschreven. De algemene regel kan gebruikt worden om voorspellingen te doen.

### 7.3.5 Tot slot

Het woord analytics omschrijft een breed scala aan handelingen waar vooral het analyseren van gegevens en het communiceren van de resultaten centraal staan. Bij Advanced Analytics wordt over het algemeen gebruik gemaakt van machine learning en datamining. In de volgende paragraaf kun je daar meer over lezen.

## 7.4 Machine learning en datamining

Machine learning en datamining zijn niet hetzelfde. Het verschil is echter zo klein dat het voor veel discussies niet zinvol is onderscheid te maken. We zullen proberen

eerst via definities het theoretische verschil duidelijk te maken. Daarna bespreken we machine learning, ervan uitgaande dat er voor bijna alle praktische toepassingen eigenlijk geen onderscheid bestaat.

### 7.4.1 Definities

De definitie van datamining volgens Gartner is: *'The process of discovering meaningful correlations, patterns and trends by sifting through large amounts of data.'*

**Datamining** is het achterhalen van verbanden, patronen en trends in gegevensverzamelingen.

Merk op dat in deze definitie geen doel van datamining staat. Waarom zou je datamining doen? Misschien is het doel wel puur het achterhalen van de verbanden en patronen. Vaak wordt als doel nog gesteld dat je met de opgedane kennis in staat bent bepaalde waarnemingen te begrijpen. Dan zijn we eigenlijk nog bezig met Diagnostic Analytics.

In veel definities van datamining wordt expliciet gezegd dat het gaat om het ontdekken van tot nu toe onbekende patronen in de data. Daarmee komt een belangrijk verschil met machine learning naar boven, waar bekende patronen worden toegepast om voorspellingen te doen.

Machine learning is een techniek waarmee computers kunnen leren van bestaande gegevens en op basis van in die gegevens aanwezige patronen voorspellingen kunnen doen.

**Machine learning** is een techniek die tot doel heeft het doen van voorspellingen op basis van bekende patronen in gegevensverzamelingen.

Formeel is datamining dus het zoeken naar onbekende patronen terwijl machine learning bekende patronen gebruikt om voorspellingen te doen. In de praktijk gebruiken bedrijven datamining om voorspellingen te doen zodra ze patronen ontdekt hebben. Net zo goed wordt machine learning gebruikt om patronen te zoeken om te kunnen gebruiken. Welke term gebruikt wordt, hangt soms af van degene aan wie je het vraagt.

De formele definitie van machine learning luidt: *'A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E'* (Tom M. Mitchell).

Belangrijk in deze definitie is het laatste stukje. Een machine learning algoritme wordt niet statisch geprogrammeerd. Het verbetert als je meer gegevens, observaties en kenmerken hebt.

In de Engelse definitie van datamining staat nog het woord 'large'. Machine learning-algoritmes worden beter als je meer observaties hebt. Beide worden vaak in één adem genoemd met Big Data. Dat is niet helemaal terecht. Datamining en machine learning bestonden al voordat de term Big Data was bedacht. Maar de link is logisch

als je bij Big Data de nadruk legt op het aantal records dat je hebt. Dat komt door de *'Law of Large numbers': 'The confidence with which predictions can be made increases as the size of the data being analyzed increases'.* Een meer formele beschrijving van deze wet kan je vinden op *https://www.britannica.com/science/law-of-large-numbers.*

De nauwkeurigheid waarmee voorspellingen gedaan kunnen worden, neemt toe als de gebruikte dataset groter wordt.

### 7.4.2 Machine learning-scenario's

Bij machine learning laten we dus een computer zelf leren op basis van (veel) gegevens. Hierbij wordt gebruik gemaakt van statistiek en andere wiskundige formules. Het gaat voor dit boek te ver om uit te leggen hoe dat precies werkt. Wel kunnen we op hoog niveau twee verschillende technieken onderkennen en uitleggen. Daarna kunnen we de verschillende scenario's bespreken.
De twee technieken die worden toegepast bij machine learning zijn:

- Supervised learning
- Unsupervised learning

*Supervised learning*
Supervised learning, ook wel learning by example genoemd, is min of meer hoe wij onze kinderen leren. Elke keer dat er een auto langsrijdt, zegt een ouder tegen zijn baby in de kinderwagen: 'auto'. We doen dat misschien wel honderden keren. Elke keer ziet de baby iets anders. Soms is het groen, dan weer blauw, dan weer nog een andere kleur. Soms is het groot, soms niet zo groot. Je kan ook zeggen dat het kind elke keer hetzelfde ziet. Een ding met kleur, vier wielen, een voorruit en twee koplampen.

Als er een fietser komt langsrijden, zegt de ouder misschien wel niets. Of hij zegt 'fiets'. De fietser kan een groene jas aanhebben, of een blauwe. Maar hij zit niet binnen en het ding waar hij op zit heeft geen vier wielen.

Op een dag komt er een auto langs en zegt de baby 'auto'. Na honderden voorbeelden heeft het kind geleerd wat wel en wat niet van belang is voor 'auto'. De kleur maakt niet uit, het aantal wielen wel. Hij heeft geleerd van eerdere observaties.

Bij supervised learning is er sprake van observaties, features en een label. Observaties zijn de rijen van onze dataset. De features zijn de kolommen in die dataset. En het label is het kenmerk, de kolom, die we willen voorspellen. In het voorbeeld willen we het type voertuig voorspellen. Fiets of auto? De features zijn in dit geval wat we allemaal zien, dus kleur, grootte, aantal wielen et cetera.

Het uitgangspunt is dat we veel gegevens uit het verleden hebben waarvan het label al bekend is. Door die gegevens te analyseren leert de computer welke kenmerken belangrijk en bepalend zijn voor de inhoud van de labelkolom. De computer leert de patronen in de data kennen die leiden tot een bepaalde waarde van het label.

**Voorbeeld**
Rond 2002 installeerde ik een opensourcespamfilter. In de eerste dagen en weken maakte dat geen verschil, ik kreeg evenveel spam als voorheen. Wel markeerde ik vanaf nu elke keer als een mailtje spam was. Langzaam maar zeker kwamen er steeds meer mailtjes waarvan ik had aangegeven of ze wel of niet spam waren. Naar verloop van tijd werden steeds meer mailtjes automatisch naar de spamfolder verplaatst. De software had geleerd van alle keren dat ik het label (wel/geen spam) had ingevuld en bleek steeds beter in staat te 'voorspellen' of een nieuw binnengekomen bericht spam was of niet.

*Unsupervised learning*

Unsupervised learning zit heel dicht aan tegen datamining. Er is geen label dat we willen voorspellen, we moeten nog onbekende patronen achterhalen. Meestal gaat het hier om het groeperen van gegevens.

Een winkelketen kan bijvoorbeeld zijn klanten indelen in groepen. Je kan je eigen 'gevoel en ervaring' gebruiken en een indeling maken naar leeftijd of geslacht. Dat is een beetje top-downdenken. Je kan ook de computer later zoeken naar klanten die qua aankoopgedrag meer of minder op elkaar lijken. Misschien komen er groeperingen uit die totaal onverwacht zijn of zelfs onlogisch klinken. Maar als het helpt om gerichter klanten te benaderen en daarmee de omzet te verhogen, is dat toch mooi meegenomen.

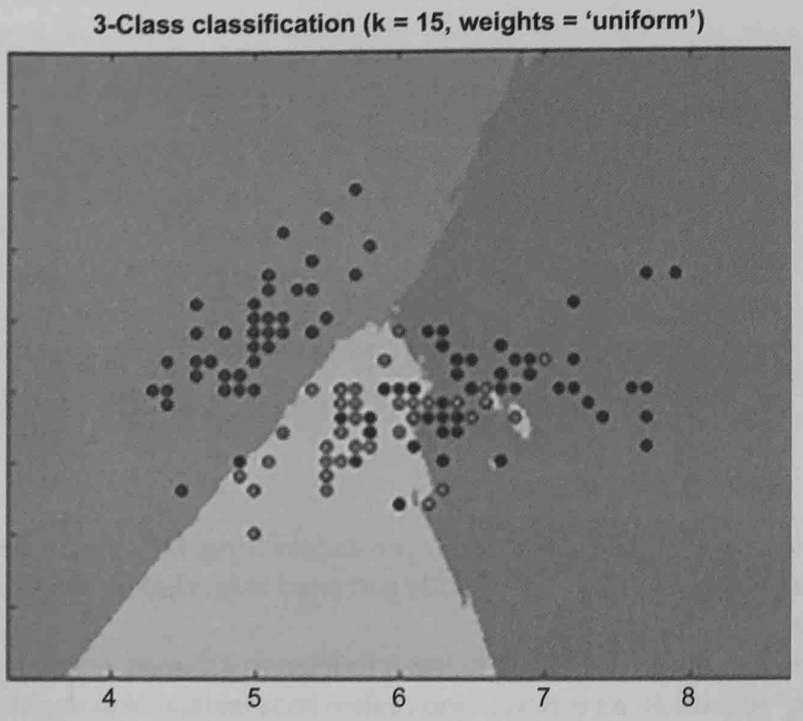
Nu we weten wat supervised en unsupervised learning is, kunnen we kijken naar toepassingen van machine learning. We zullen kort kijken naar:

- Classification
- Clustering
- Outlier detection
- Regression

*Classification*

Classification is een supervised learning-techniek waarbij records worden ingedeeld in van tevoren bekende categorieën. Het genoemde voorbeeld van het spamfilter is een voorbeeld van two-class classification. Fraudedetectie is een ander voorbeeld. Als er veel schadeclaims uit het verleden al zijn geoormerkt als wel of niet frauduleus, kan dat gebruikt worden om met classification van nieuwe claims te voorspellen of het om fraude gaat of niet.

Je kan onderscheid maken tussen two-class- en multi-class classification. Bij two-class heeft het te voorspellen label maar twee mogelijke waarden, bijvoorbeeld wel of geen spam. Bij multi-class kunnen er meer mogelijke waarden zijn.




**Figuur 7.4** *Classification*

Er zijn verschillende wiskundige algoritmes die je kan toepassen bij classification. Support vector machines, decision trees, decision forests, logistic regression en neural networks zijn voorbeelden van algoritmes die hiervoor gebruikt worden.

Welk algoritme je kiest, hangt af van verschillende zaken. Hoeveel rijen heb je en uit hoeveel (relevante) features bestaan die? Welke patronen bevinden zich in de gegevens? Maar ook zaken als: hoeveel tijd hebben we om te trainen? Deze keuzes zijn niet voor de hand liggend, maar kunnen wel bepalend zijn voor de uitkomst. Data scientists moeten deze keuzes maken.

*Clustering*

Clustering is een unsupervised learning-techniek die gegevens groepeert in 'clusters' van vergelijkbare records. Wat vergelijkbaar betekent, is niet van te voren te voorspellen. Het hangt uiteraard weer af van de data die je hebt en het algoritme dat je gebruikt.

Het resultaat van clustering kan in een later stadium gebruikt worden in een classificationscenario.

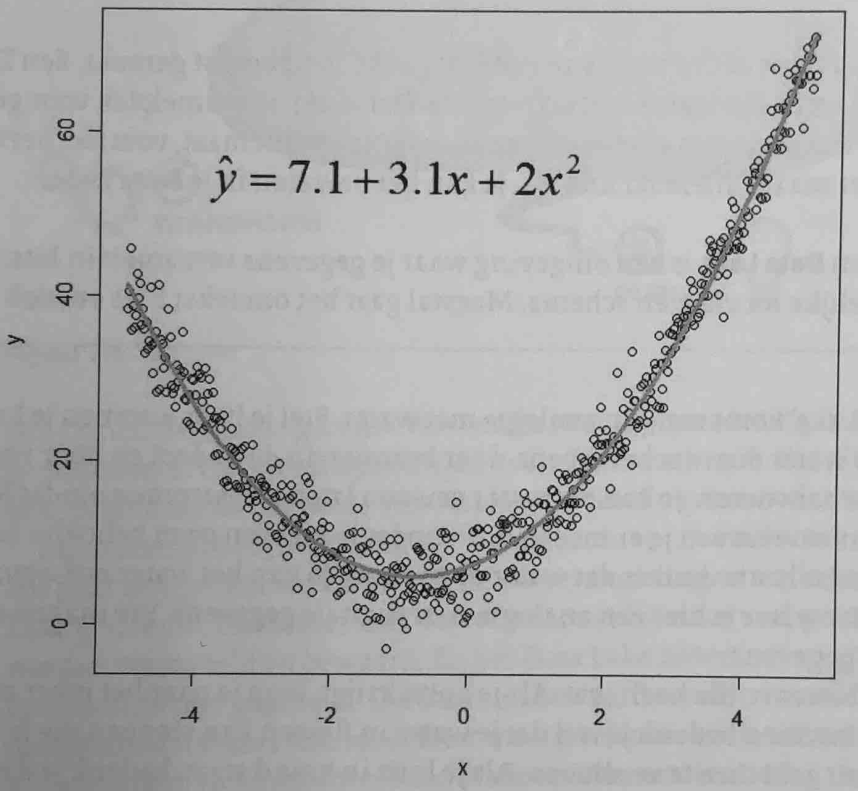
K-means is een veel gebruikt algoritme voor clustering.

*Outlier detection*

Outlier detection is sterk verwant aan zowel classification als aan clustering. Het kan ook zowel supervised als unsupervised zijn. Het verschil zit hem voornamelijk in het aantal rijen (observaties) in een groep. Als je met clustering je gegevens probeert in te delen in twee groepen, kan je dat doen door twee groepen te maken die elk ongeveer evenveel rijen bevatten. Bij het voorbeeld van het spamfilter hoop je meer rijen te hebben die geen spam zijn dan wel spam, maar helaas zal 'wel spam' nog steeds regelmatig voorkomen.

Bij outlier detection gaat het om het vinden van één of enkele records die anders zijn dan alle andere.

*Regression*
Regression gaat uit van een oorzakelijk verband tussen twee variabelen, ofwel grootheden. In het voorbeeld van de ijsverkoper gaat de omzet omhoog als de temperatuur omhoog gaat. De temperatuur wordt nu de onafhankelijke variabele genoemd. De onafhankelijke variabele gebruik je om de afhankelijke variabele, in dit voorbeeld de omzet, te berekenen. Alles wat je moet weten is de wiskundige formule die de afhankelijkheid tussen temperatuur en omzet beschrijft.




**Figuur 7.5** *Regression*

### 7.4.3 Tot slot

Er zijn veel algoritmes waaruit een data scientist kan kiezen bij de verschillende scenario's. Hij zal gedegen statistische kennis nodig hebben om de gegevens te analyseren, de juiste algoritmes te kiezen, de juiste parameters te kiezen en de uitkomsten op de juiste waarde te schatten.

Er zijn veel tools op de markt die de data scientist tot zijn beschikking heeft. De de facto standaard is de opensourcetaal R. Maar ook de programmeertaal Python wordt veel gebruikt.

Verlies niet uit het oog waar het omgaat. Machine learning is een component van analytics. Het doel is besluitvorming te ondersteunen. Uiteindelijk willen we er competitief voordeel uit halen. En daarmee vormt het een goede aanvulling (is het een component van) Business Intelligence.

## 7.5 Big Data Tools - Data Lake - noSQL

Na het uitstapje naar analytics gaat deze paragraaf weer over Big Data. Het uitstapje is echter geen toeval. In paragraaf 7.4.1 is de 'law of large numbers' genoemd. Daarnaast is al enkele keren benoemd dat klassieke datawarehouses (en vooral de datamarts die mensen mogen gebruiken) in veel gevallen niet voldoen voor Advanced Analytics. Big Data-oplossingen kunnen uitkomst bieden. Om dat te begrijpen bespreken we eerst het concept Data Lake. Daarna kijken we naar (eisen aan) tools die we kunnen gebruiken.

### 7.5.1 Data Lake

Met Big Data is ook het concept van een Data Lake in opkomst geraakt. Een Data Lake is misschien wel het nieuwe datawarehouse. Het is een verzamelplek voor gegevens. Allerlei soorten gegevens, wat voor gegevens dan ook. Formaat, volume, herkomst, kwaliteit, het maakt allemaal niet uit. Je kan het bewaren in je Data Lake.

Een **Data Lake** is een omgeving waar je gegevens verzamelt in hun oorspronkelijke formaat en schema. Meestal gaat het om tekst files en blob files.

---

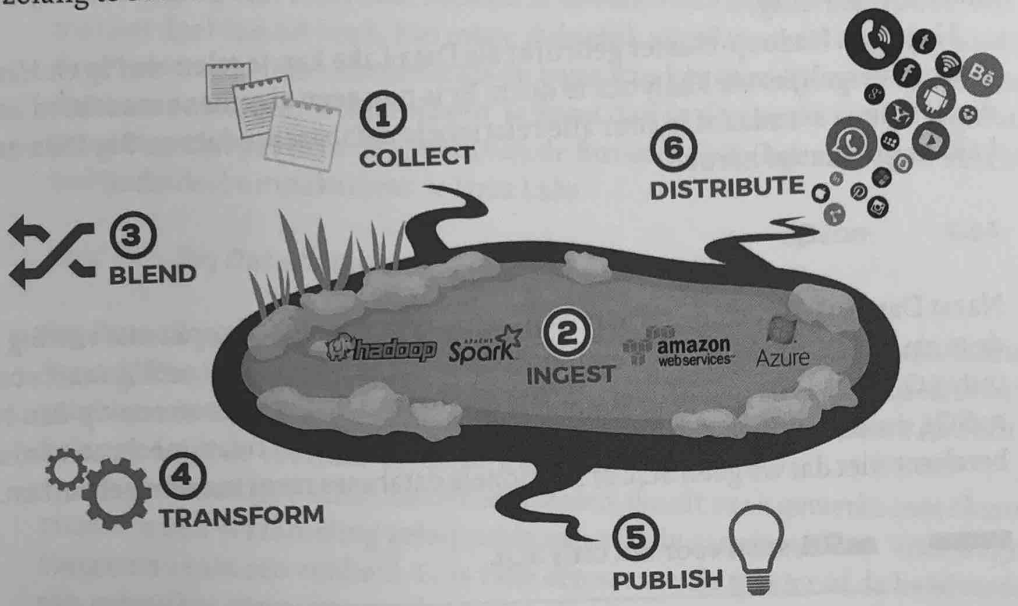
Het woord 'Lake' komt van een analogie met water. Stel je hebt water en je krijgt constant nieuw water doordat het regent, door bronnen in de bodem en door rivieren die nieuw water aanvoeren. Je kan dat water gewoon laten wegstromen omdat je er niets mee kan of niet weet wat je er mee kan, of omdat je nu even geen behoefte hebt aan water, of omdat het te duur is dat water op te slaan. Je kan het water ook opvangen in een meer. Het water is hier een analogie voor digitale gegevens. We maken een meer vol digitale gegevens.

Wie wat bewaart, die heeft wat. Als je dorst krijgt, loop je naar het meer om wat te drinken. Misschien bedenk je wel dat je water in flessen kan stoppen die je kan verkopen. Er valt geld mee te verdienen. Als je huis in brand staat, bedenk je dat je water in emmers kan doen om de brand te blussen. Als je stroom nodig hebt, laat je het uit je meer lopen om waterkrachtenergie op te wekken. Wie weet wat je nog meer met water kan. Wie weet wat je nog meer met data kan!

De moraal is: alle gegevens hebben waarde. Wat je weggooit, ben je definitief kwijt. Dus gooi niets weg. Zelfs als je nu niet weet wat met de gegevens te doen, is het zonde om ze weg te gooien. Met digitale foto's konden we een paar jaar geleden niet zo veel. Nu kunnen we door de vooruitgang in machine learning gezichtsherkenning en emotiedetectie loslaten op foto's en daarmee nuttige informatie boven water krijgen. Tenzij je al je foto's al hebt weggegooid natuurlijk...

Een impliciete aanname die bij Data Lakes wordt gemaakt, is dat het opslaan van gegevens tegenwoordig niet meer duur is. Harde schijven zijn tegenwoordig groot in capaciteit en goedkoop. Ook de cloud speelt hier een rol. De cloud heeft een oneindige capaciteit, zolang je maar betaalt.

Goedkoop is niet gratis. De echte aanname is dat wat je ooit met de opgeslagen gegevens in je Data Lake gaat doen, meer waard is dan de kosten die je moet maken om het zolang te bewaren.




**Figuur 7.6** *Data Lake*

Een Data Lake maakt gebruik van een bottom-upbenadering. Data worden niet vooraf geprepareerd. Het wordt opgeslagen zoals het ontstaan is. Pas als we het gaan gebruiken, passen we de gegevens aan aan het specifieke gebruik dat we voor ogen hebben.

Bij sommige bedrijven is Data Lake een concept dat zich niet een-op-een laat vertalen naar een product of een systeem. De verzameling van alle gegevens wordt het Data Lake genoemd. Daar hoort het datawarehouse bij waar veel gestructureerde gegevens worden verzameld en bewaard. Bij het Data Lake horen net zo goed de semi- en ongestructureerde gegevens. Die kunnen bewaard worden in noSQL-databases zoals document databases (hierover later meer), als losse bestanden op een harde schijf, of als bestanden in bijvoorbeeld een Hadoop-cluster. Het Data Lake wordt dan gevormd door meerdere producten samen.

Met Data Lake kan ook een product of een enkel systeem bedoeld worden. Microsoft biedt Data Lake aan als een service in Azure. In dat geval bevat het Data Lake de niet-gestructureerde gegevens en zitten de gestructureerde gegevens 'gewoon' in een relationeel datawarehouse.

*Data Lake Analytics*

Aan alleen verzamelen en opslaan van gegevens heb je uiteindelijk niets. Je moet iets met die gegevens kunnen doen. Dat zou je Data Lake Analytics kunnen noemen. Een deel van het idee van Data Lake is dat je nu heel veel gegevens van verschillende bronnen samen hebt gebracht op één plek, zodat je ze samen kan gebruiken. Dat is waar de analytics begint. Analyseer de gegevens, combineer de gegevens en gebruik de resultaten voor machine learning, reporting en visualisaties.

Met welke technieken je analytics gaat doen op de Data Lake is afhankelijk van eerder gemaakte keuzes. Als je voor Microsoft Azure Data Lake hebt gekozen kan

je gebruikmaken van de taal U-SQL die je in staat stelt gegevens in files gemakkelijk te combineren (joinen) met gegevens in tabellen in SQL Server. Zo kan je met SQL-achtige query's bruikbare resultsets maken voor reporting of voor bijvoorbeeld machine learning.

Als je een Hadoop-cluster gebruikt als Data Lake kan je talen als Pig en Hive gebruiken om vergelijkbare analytics te doen. Er is nog geen algemene standaard zoals SQL de algemene standaard is voor alle relationele databaseproducten. Big Data en Data Lakes zijn relatief nieuw.

### 7.5.2 noSQL

Naast Data Lake is ook de term noSQL geïntroduceerd met de opkomst van Big Data. Met de term noSQL probeert men een soort database aan te duiden. noSQL staat voor 'not only SQL'. SQL is de taal van relationele databases. Die twee horen een-op-een bij elkaar. noSQL duidt daarmee op alle databaseplatformen die niet relationeel van aard zijn. Het betekent niet dat we geen SQL of relationele databases meer moeten gebruiken.

**noSQL** staat voor not only SQL.

noSQL-databases proberen tekortkomingen van relationele databases te ondervangen. Bij grote webshops, social media-sites, Internet of Things-applicaties en andere meer moderne toepassingen lopen bedrijven aan tegen de grenzen van relationele databases. Vaak heeft dat te maken met het minder gestructureerd zijn van gegevens, de snelheid waarmee gegevens ontstaan of het volume aan digitale data dat we moeten verwerken. Kortom, kenmerken van Big Data. Er blijven ook nog heel veel scenario's over waarbij relationele databases prima voldoen.

*Document database*

Document databases zijn een voorbeeld van noSQL-databases. MongoDB en DocumentDB zijn voorbeelden van document databases. In deze databases worden gegevens opgeslagen in de vorm van JSON-documenten. Een van de voordelen is dat elk opgeslagen JSON-document intern een andere structuur kan hebben. Je zit dus niet vast aan een schema en een vaste structuur.

Bovendien kunnen gegevens meer worden opgeslagen zoals ze worden gebruikt. Er is minder behoefte gegevens te 'normaliseren' en verdeeld over meer tabellen op te slaan. Dat kan de performance en schaalbaarheid ten goede komen.

*Graph database*

Een ander voorbeeld van noSQL-databases zijn graph databases. Neo4j is een voorbeeld. Graph databases gaan er vanuit dat alles met alles in verband staat en dat wij geïnteresseerd zijn in die verbanden. Graph databases slaan verbanden op, waardoor ze gemakkelijk, snel en schaalbaar op te zoeken zijn.

Een voor de hand liggend voorbeeld is LinkedIn. Constant wordt bijgehouden wie met wie gelinked is, wie welke posts geschreven of gelezen heeft, wie welke skills heeft et cetera. Gezien de schaal gaat het om snel en veel. Om snel een timeline van

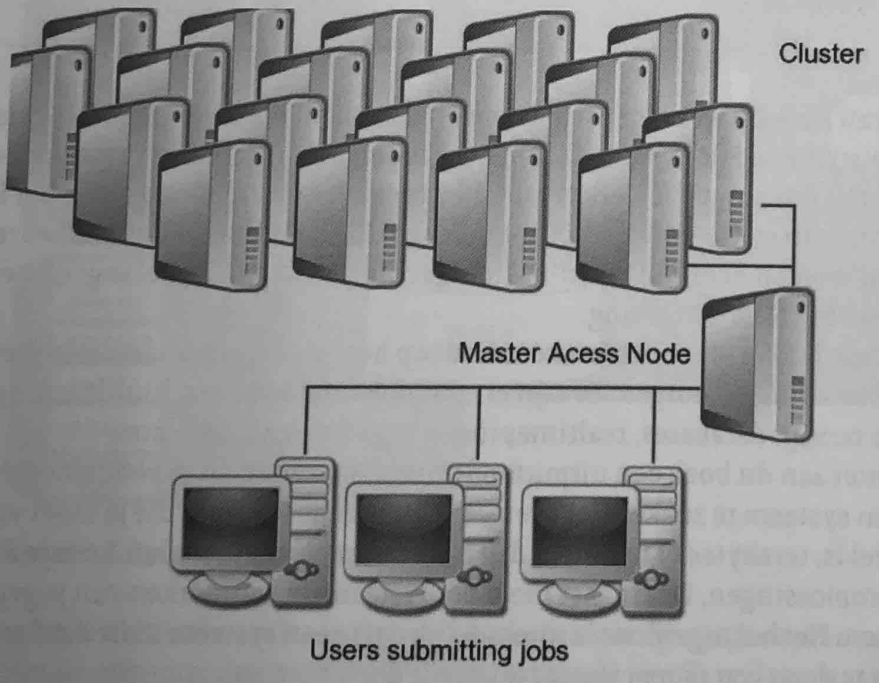
iemand te kunnen vullen, moet vastgelegd zijn wie met wie gelinked is en wat er is gepost of geliket. Je hebt geen tijd om dat te gaan uitzoeken op het moment dat iemand zijn app opent.

Er zijn nog veel meer voorbeelden te noemen van noSQL-databases. Dat is echter niet het doel van dit boek. Het moge duidelijk zijn dat zowel op het gebied van specifieke gevraagde functionaliteit als op basis van kenmerken van je gegevens, relationele databases niet meer altijd voldoen. Je komt dan in de wereld van de Big Data terecht, maar nog niet per se in de wereld van de Business Intelligence. Deze databases kunnen wel onderdeel uitmaken van je Data Lake.

### 7.5.3 Big Data-databases

Big Data-databases zijn over het algemeen noSQL-databases. Als datavolume het enige kenmerk is dat Big Data-innovaties stuurt, kan een appliance van een relationeel product misschien nog uitkomst bieden. Zijn er meer kenmerken van doorslaggevend belang of zijn de volumes extreem, dan wordt het noSQL.

Om de benodigde schaalbaarheid te halen, wordt vaak gewerkt met clusters. Een cluster is een verzameling gekoppelde servers die samenwerken. Voor de gebruiker fungeren ze als een eenheid. Er is vaak één server, de master of de head node, waarmee een gebruiker connectie maakt. Achter de schermen wordt het werk echter verdeeld over verschillende nodes (servers) in het cluster.




**Figuur 7.7** *Cluster*

Een **cluster** is een verzameling gekoppelde servers die samenwerken alsof ze één zijn.

Een goed cluster is lineair schaalbaar. Dat betekent dat als je een query twee keer zo snel wilt maken, je die query door twee keer zoveel servers moet laten verwerken. Net zo goed is dezelfde query op een twee keer zo grote dataset even snel als voorheen indien je hem weer over twee keer zo veel servers verdeeld.

Bij een cluster hoort ook een distributed file system. Zoals hierboven beschreven wordt het rekenwerk, de CPU-belasting, verdeeld over meer computers. Ook de opslag van bestanden moet verspreid over meer servers plaatsvinden. Als meer servers tegelijkertijd met een bestand gaan werken en dat bestand staat in zijn geheel op één harde schijf, ontstaat er een bottle neck. Het schaalt niet meer.

Een distributed file system laat gebruikers werken met bestanden zoals we dat gewend zijn. Eén bestand is één bestand. Achter de schermen wordt het bestand in kleine stukken geknipt en verspreid over meerdere servers opgeslagen. Als je het een beetje slim doet, kan elke server die een stukje van het bestand heeft, dat stukje verwerken als er query's gebruikmaken van het bestand.

Een van de bekendste voorbeelden van zo'n Big Data-oplossing is waarschijnlijk Hadoop. Hadoop is een opensourcesoftwareraamwerk waarmee computerclusters tot vele petabytes aan ongestructureerde data op commodity hardware kunnen verwerken (*computerworld.nl/big-data/75185-wat-is-hadoop*). Belangrijk hier is het woord softwareraamwerk.

**Hadoop** is een opensourceraamwerk van software voor Big Data-toepassingen.

Het hart van Hadoop wordt gevormd door HDFS, MapReduce en Yarn. HDFS is het Hadoop Distribited File System. MapReduce is een programmeer framework dat er automatisch voor zorgt dat werk verspreid wordt over meerdere nodes in het Hadoop-cluster. Yarn, ten slotte, is een resource manager die coördineert dat hardware resource efficiënt worden benut in multi-useromgevingen. Dit zijn de belangrijkste kenmerken van een Big Data-omgeving.

Naast deze hoofdcomponenten kent Hadoop heel veel extra onderdelen die voor specifieke functionaliteit zorgen. Zo zijn er componenten voor machine learning, graphen andere noSQL-databases, realtimeprocessing en ga zo maar door.

Het is niet aan dit boek een uitputtende lijst van producten te benoemen. Het is van belang een systeem te zoeken dat overweg kan met de volumes die je moet verwerken. Als dat veel is, terabytes of meer per dag dat verwerkt moet worden, kom je al snel uit bij clusteroplossingen. Daarnaast moet het systeem de kenmerken van je gegevens aankunnen. Het belangrijkste is uiteindelijk dat je een systeem kiest dat functioneel in staat is te doen wat jij met je gegevens wilt doen.

## 7.6 Big Data en datawarehousing

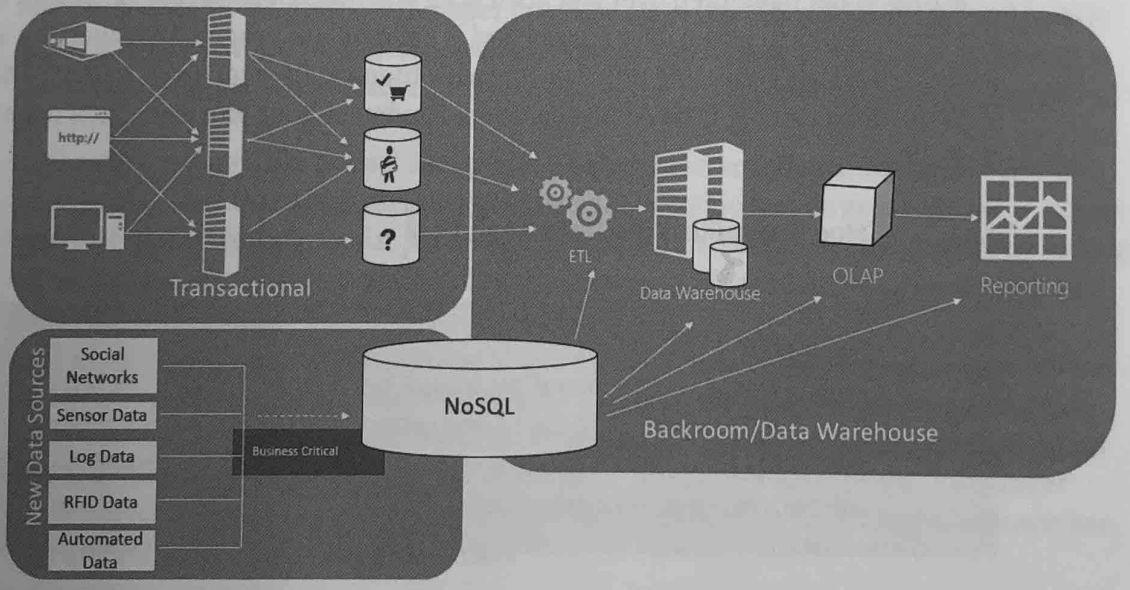
De vraag die na het lezen van dit hoofdstuk misschien rijst is of Big Data de klassieke datawarehouses, zoals beschreven in de eerdere hoofdstukken van dit boek, gaan ver-

vangen. Het antwoord is nee, zeker niet binnen afzienbare tijd. Big Data is een aanvulling op klassieke Business Intelligence en datawarehousing.

De eerste reden waarom Big Data klassieke BI niet gaat vervangen is de blijvende behoefte aan Descriptive Analytics. Banken moeten verantwoording afleggen aan overheden. Ziekenhuizen moeten verantwoording afleggen aan verzekeringsmaatschappijen. Bedrijven moeten verantwoording afleggen aan investeerders. Daarvoor zullen ze vaak gegevens uit verschillende bronnen moeten combineren, de gegevens prepareren voor gebruik en definities moeten opnemen over de betekenis van data. Allemaal zaken waar datawarehouses heel goed functioneren.

Een andere reden waarom datawarehouses zullen blijven bestaan, is het feit dat uiteindelijk toch veel gegevens wel gestructureerd zijn. Zoek je naar systemen die heel goed zijn in het verwerken van gestructureerde gegevens, dan kom je nog altijd uit bij relationele databases. Zeker daar waar het gaat over het mkb (midden- en kleinbedrijf) waar de data volumes niet in de terabytes lopen.

Langzaam maar zeker zullen we gaan richting architecturen zoals beschreven in figuur 7.8. Het kader links bovenin het plaatje toont transactionele applicaties die gestructureerde gegevens genereren in relationele databases. Via een ETL-proces worden de gegevens overgehaald en geïntegreerd opgenomen in een klassiek relationeel datawarehouse. Dit heeft in het verleden goed gewerkt en werkt nog altijd goed.




**Figuur 7.8** *Big Data BI-architectuur*

In het kader links onder in figuur 7.8 worden nieuwe gegevensbronnen getoond. Met de opkomst van nieuwe zaken zoals sociale media en Internet of Things, zijn er nieuwe soorten gegevens ontstaan. Gegevens met andere kenmerken. En die gegevens vragen om een andere benadering.

Naast nieuwe gegevensbronnen zijn we ook in staat met moderne technieken om gegevens te verwerken die voorheen niet zinvol waren om te verwerken. Enkele jaren geleden werd de signal-to-noiseratio van bijvoorbeeld logfiles te laag gevonden om deze gegevens economisch zinvol te analyseren. Tegenwoordig kunnen we dat wel. Maar niet met technieken die je terugvindt in relationele databases (nóg niet, tenminste).

Tot slot zijn we met Advanced Analytics andere vragen gaan stellen. Vanwege de nieuwe gegevens die we hebben en door de nieuwe analyses die we uitvoeren, hebben we nieuwe systemen nodig. Zie daar de introductie van noSQL-databases.

In het rechterkader van figuur 7.8 zien we dat beide werelden uiteindelijk samenkomen. Analytics houdt uiteindelijk ook het communiceren in van de gevonden resultaten. Dat kan op aparte rapporten die aangeboden worden in de centrale rapportageomgeving. Het kan ook zijn dat we de resultaten die Big Data-verwerkingen opleveren al op een eerder moment integreren in de BI-oplossing. Een met Big Data-technieken gemaakte dataset kan prima opgenomen worden in het relationele datawarehouse.

Zoals in paragraaf 7.2 al is gezegd: Big Data is aanvullend op klassieke BI. Het is geen vervanging van klassieke BI.

## 7.7 Big Data en ethiek

The sky is the limit met Big Data Analytics. Hoe meer gegevens je hebt, hoe meer informatie je daar uit kan halen. En informatie is kennis en kennis is macht. Het is goed om stil te staan bij de wenselijkheid van dit alles. Waar ligt de grens van wat wel en niet ethisch verantwoord is?

Ethiek is het nadenken over wat goed is en wat niet. Deze paragraaf is niet bedoeld om antwoorden te geven. Deze paragraaf is bedoeld om vragen op te werpen waar de samenleving als geheel, de politiek, en misschien jijzelf, over moet nadenken. Ook bedrijven die aan Big Data Analytics doen, zouden er goed aan doen zich deze vragen te stellen.

### 7.7.1 Hoe wenselijk is Big Data Analytics?

**Voorbeeld**

Laatst hoorde ik van iemand dat hij was benaderd door een ziektekostenverzekeraar. Hij kreeg te horen dat hij een gezonde, sportieve, hoogopgeleide man van middelbare leeftijd was met een goed inkomen. Daarom kon de verzekeraar hem een zeer voordelige polis aanbieden.

Wat te denken van bovenstaand voorbeeld? In eerste instantie zou je misschien denken: iedereen blij. De persoon in kwestie een goedkope verzekering, de verzekeringsmaatschappij een goedkope klant. Maar riekt dit niet naar discriminatie? Wordt het racisme als we het kenmerk 'blank' toevoegen? Geldt omgekeerd dat een laagopgeleid persoon een hogere premie moet betalen? Of kunnen op den duur mensen die niet aan dit profiel voldoen helemaal geen ziektekostenverzekering meer afsluiten? Hoe ziet onze maatschappij er dan uit?

De Big Data Analytics die hier achter zit, is dat bedrijven in staat zijn persoonsgegevens van klanten en potentiële klanten te achterhalen. Ook gegevens over leefstijl zijn zo voor handen. Een eenvoudige statistische analyse leert welk type mens veel of

weinig ziektekosten gaat hebben. Beide combineren levert al snel een aantrekkelijke marketingstrategie op.

In dit voorbeeld gebeurt niets illegaals, maar we bevinden ons wel op een hellend vlak. Misschien moet de overheid bepalen waar de grens ligt tussen wat is toegestaan en wat niet. Maar ook de overheid zet Big Data Analytics op grote schaal in. Onder het mom van de nationale veiligheid analyseren geheime diensten heel veel gegevens. Wie belt met wie? Hoe vaak en hoe lang? Neemt de intensiteit toe?

Met een beetje pech komt er uit de overheidsgegevens dat jij schuldig bent aan iets illegaals. Ben je nu onschuldig tot het tegendeel is bewezen of wordt de bewijslast omgedraaid en moet jij bewijzen dat je onschuldig bent? Als we niet oppassen wordt de bodem onder onze huidige rechtsstaat weggeslagen.

Er zijn veel voorbeelden van overheidsdiensten die gegevens koppelen. Bijvoorbeeld om fraude op te sporen. Het argument is dat de samenleving als geheel er bij gebaat is, omdat zo 'het belastinggeld van de burger' beter besteed wordt. Maar wat betekent dit voor onze privacy?

Nog een voorbeeld is de aankoop van WhatsApp door Facebook. WhatsApp is een gratis dienst. Eentje die belooft dat je geen advertenties te zien krijgt. Hoe verdient Facebook de miljarden die ze betaald hebben terug? Als we ons meer gaan realiseren dat Facebook en Google bij alles wat we doen meekijken, gaan we ons waarschijnlijk anders gedragen. Als de glazenwasser door het raam naar binnen kijkt terwijl je in je ondergoed zit te ontbijten, trek je wellicht eerder kleren aan. Je verandert je gedrag omdat iemand meekijkt. Dat tast de kern van onze privacy aan. Is dat anders op het internet?

Op het internet lijkt er heel veel gratis. Spelletjes en sociale media, we betalen er geen geld voor. Maar als je niet met geld betaalt, betaal je met de gegevens die je achterlaat. Dat houdt wellicht in dat je met je privacy betaalt. Facebook analyseert ons gedrag en verkoopt/gebruikt de resultaten. Facebook weet vaak eerder wat jij leuk vindt dan dat je dat zelf weet!

Veel mensen vinden dat tegenwoordig niet erg omdat ze 'niets te verbergen' hebben. Het probleem is dat je vaak niet weet wat er met je gegevens gebeurt. Of wat er in de toekomst nog mee gedaan gaat worden. Daar zouden best eens zaken tussen kunnen zitten waar je eigenlijk wel bezwaar tegen hebt. Misschien krijg je wel nooit meer werk omdat uit een of andere analyse komt dat je lui bent en slecht kan samenwerken met anderen. Is het dan nog steeds oké?

### 7.7.2 Wet- en regelgeving

Bovenstaande komt er op neer dat we moeten discussiëren over de ethiek van Big Data en analytics. De overheid zal met wet- en regelgeving moeten komen. Die regels zullen echter nooit in alle situaties kunnen voorzien. Dus moeten bedrijven ook interne regels opstellen over het omgaan met de mogelijkheden van Big Data en de implicaties die dat heeft. Daarbij moet je nadenken over onder andere:

- Privacy
- Transparantie
- Discretie
- Identiteit

*Privacy*

Onder privacy moeten we verstaan de regels die we opstellen over het vergaren van gegevens, het gebruik van die gegevens en de duur dat we die gegevens gaan bewaren. Bij het opstellen van regels hoort ook het naleven van regels en de controle op die naleving.

Als de overheid zegt dat camera's boven de weg alleen gebruikt worden voor snelheidscontrole, moet dat gegarandeerd en gecontroleerd worden. De gegevens gebruiken om files beter te voorspellen kan dan niet. Laat staan het controleren of je daadwerkelijk elke dag met je leaseauto naar je werk gaat!

Samen met privacy moet je nadenken over wie eigenaar is van de gegevens. Je moet zelf kunnen bepalen wat er met je gegevens gebeurt. Sommige sociale media hebben in de algemene voorwaarden wel zaken opgenomen. Voor sommige gebruiken is er een opt-in- of opt-outmogelijkheid. Regelmatig zijn die voorwaarden en opties zo goed verstopt, of zo complex opgesteld, dat mensen ze niet lezen of niet snappen. Daarmee kom je bij transparantie.

*Transparantie*

Het moet duidelijk zijn voor de eigenaar van de gegevens, of voor degene over wie de gegevens gaan, wat er mee gebeurt. Het al dan niet ethische zit vaak in het tweede gebruik. Dat een bank al je transacties bijhoudt om te weten wat je saldo is, het primaire gebruik, is oké. Maar wat als de bank die gegevens verkoopt aan winkelketens zodat zij dat kunnen gebruiken voor gerichte marketing en op maat gemaakte aanbiedingen? Misschien dat je dat juist fijn vindt, misschien ook wel niet.

Belangrijk bij dit secundaire gebruik is dat het duidelijk kenbaar wordt gemaakt welke gegevens door wie gebruikt gaan worden en met welk doel. Daarbij hoort dan weer de optie dat wel of niet toe te staan.

Een probleem kan ontstaan als alle banken in hun algemene voorwaarden opnemen dat ze klantgegevens gaan verkopen. Als je daar op tegen bent, kan je geen enkele bankrekening meer openen. Je werkgever eist echter dat je een rekening hebt want ze betalen je salaris niet in contanten uit. Hier heeft de overheid duidelijk een rol te vervullen.

*Discretie*

Tenzij je je helemaal uit de maatschappij terugtrekt, ontkom je er niet aan een digitaal spoor achter te laten. Het bewust geen mobiele telefoon nemen omdat je niet wilt dat telefoonaanbieders kunnen zien waar je bent, heeft grote sociale gevolgen. Geen WhatsApp hebben omdat je Facebook niet vertrouwt, ook als bijvoorbeeld je voetbalteam alle afspraken en verzameltijden deelt via een WhatsAppgroep, heeft tegenwoordig verstrekkende consequenties voor je dagelijkse leven.

Belangrijk is dat je er op moet kunnen vertrouwen dat er discreet met jouw gegevens wordt omgesprongen. Je wilt niet dat je baas, of de overheid, via gegevens die voor andere doeleinden zijn bedoeld, weet waar jij 's avonds uithangt. Als je zelf op sociale media deelt waar je uithangt, is dat heel wat anders dan wanneer een telecombedrijf dat tegen betaling aan iemand vertelt doordat ze je telefoon traceren.

*Identiteit*

Mensen zijn kuddedieren. Of we het nu leuk vinden of niet, hoe individualistisch onze samenleving misschien wel is, de overeenkomsten tussen groepen mensen zijn groter dan de verschillen. Op basis van demografische gegevens kan het kiesgedrag van hele wijken worden voorspeld. Maar met de huidige mogelijkheden kunnen we zelfs kiesgedrag van individuen voorspellen. Campagneteams weten eerder dan kiezers zelf wat ze gaan stemmen. Ze weten ook hoe ze kiezers kunnen beïnvloeden om wel of niet te gaan stemmen. Is er zo nog wel sprake van eerlijke, vrije verkiezingen?

Het gaat er hier om dat we onze eigen identiteit kwijtraken. Dat gaat verder dan privacy. Het gaat hier om wie je bent. Het gaat erover dat onbekenden beter weten wie jij bent en hoe jij waar op reageert, dan dat jij dat zelf weet. Met die kennis kunnen (en zullen) ze jouw gedrag gaan beïnvloeden. Dat gebeurt al jaren op grote schaal en dat heet reclame en marketing. Er is echter een verschil als groepen mensen het doel zijn dan wanneer mensen individueel getarget worden. Nog erger is als je je helemaal niet meer bewust bent dat je beïnvloed wordt, waar je voorheen nog wel wist dat je naar reclame keek.

### 7.7.3 Tot slot

Dit is geen boek over filosofie of ethiek. Maar het onderwerp van dit hoofdstuk werpt wel vragen op over ethische kwesties. Wet- en regelgeving vanuit overheden loopt (bijna) altijd achter bij de technische mogelijkheden. Zelfs waar dat niet zo is, zal de wet niet volledige duidelijkheid verschaffen voor de situaties die kunnen optreden. Niet alle vragen die je kan stellen, zullen door de wet beantwoord worden. Het is dus goed om als bedrijf zelf ook met beleid omtrent Big Data te komen.

Gelukkig hoef je niet zelf het wiel uit te vinden. De Data Science Association (*www.datascienceassn.org*) heeft gedragsregels opgesteld voor data scientists als houvast bij ethische vragen. Er zijn ook andere organisaties die vergelijkbare initiatieven hebben.

Zowel als maatschappij, als ook binnen bedrijven, is het noodzakelijk om stil te staan bij de ethische kant van Big Data Analytics.

## 7.8 Voorbeeld van datamining met Excel

Ook in dit hoofdstuk zullen we weer een hands-on voorbeeld uitwerken om wat meer feeling te krijgen bij de geleerde theorie. Deze kan je lezen op *www.leerboekbusinessintelligence.nl*.

## 7.9 Tot Slot

Big Data heeft een hele nieuwe wereld geopend. Een belangrijke conclusie van dit hoofdstuk is dat al die nieuwe mogelijkheden aanvullend zijn op wat Business Intelligence altijd al was. Technisch gezien komt het daarmee naast klassieke data-

warehouses te staan. Dit wil niet zeggen dat je niet alleen Big Data of alleen datawarehousing kan doen.

In de loop van dit hoofdstuk zijn semantische modellen al genoemd. In de architectuur zoals getoond in figuur 7.8 zijn ze ook al te zien. In het volgende hoofdstuk kan je lezen over het wat en waarom van semantische modellen.